

A Conceptual Introduction to Markov Chain Monte Carlo Methods

Joshua S. Speagle

Center for Astrophysics | Harvard & Smithsonian, 60 Garden St., Cambridge,
MA 02138, USA

jspeagle@cfa.harvard.edu

Аннотация

Методы Монте-Карло с цепью Маркова (МСМС) стали краеугольным камнем многих современных научных анализов, поскольку обеспечивают простой подход к численной оценке неопределенностей в параметрах модели с использованием последовательности случайных выборок. Эта статья представляет собой базовое введение в методы МСМС, устанавливая четкое концептуальное понимание того, какие проблемы пытаются решить методы МСМС, почему мы хотим их использовать и как они работают в теории и на практике. Чтобы развить эти концепции, я излагаю основы байесовского вывода, обсудите, как апостериорные распределения используются на практике, изучите основные подходы к оценке величин, основанных на апостериорных данных, и выведите их связь с выборкой по методу Монте-Карло и МСМС. Затем, используя простую игрушечную задачу, я продемонстрирую, как эти концепции могут быть использованы для понимания преимуществ и недостатков различных подходов МСМС. Упражнения, предназначенные для освещения различных концепций, также включены в статью.

1 Introduction

Научный анализ обычно основывается на выводах о лежащих в основе физических моделях из различных источников данных наблюдений. За последние несколько десятилетий качество и количество этих данных существенно возросли, поскольку их сбор и хранение стали быстрее и дешевле. В то же время та же технология, которая позволила собирать огромные объемы данных, также привела к существенному увеличению вычислительной мощности и ресурсов, доступных для их анализа.

В совокупности эти изменения позволили исследовать все более сложные модели с использованием методов, которые может использовать эти вычислительные ресурсы. Это привело к резкому увеличению числа опубликованных работ, основанных на методах Монте-Карло, которые используют комбинацию численного моделирования и генерации случайных чисел для изучения этих моделей.

Одно особенно популярное подмножество методов Монте-Карло известно как Цепочка Маркова Монте-Карло (МСМС). Методы МСМС привлекательны тем, что они представляют простой, интуитивно понятный способ как моделировать значения из неизвестного распределения, так и использовать эти смоделированные значения для выполнения последующего анализа. Это позволяет им применяться в самых разных областях.

Благодаря широкому использованию различные обзоры методов МСМС распространены как в рецензируемых, так и в не рецензируемых источниках. В целом, они, как правило, делятся на две группы: статьи, посвященные различным статистическим основам методов МСМС, и статьи, посвященные внедрению и практическому использованию. Читателям, заинтересованным в более подробном ознакомлении с любой из этих тем, рекомендуется ознакомиться с Brooks et al. (2011) и Hogg & Foreman-Mackey (2018) вместе с соответствующими ссылками в них.

Вместо этого в этой статье представлен обзор методов МСМС, направленных на формирование четкого концептуального понимания того, что, почему и как в МСМС, основанного на статистической интуиции. В частности, в нем предпринята попытка систематически ответить на следующие вопросы:

1. Какие проблемы пытаются решить методы МСМС?
2. Почему мы заинтересованы в их использовании?
3. Как они работают в теории и на практике?

Отвечая на эти вопросы, в этой статье обычно предполагается, что читатель в некоторой степени знаком с основами байесовского вывода в теории (например, роль априорных значений) и на практике (например, получение апостериорных значений), базовой статистикой (например, математические ожидания) и основными численными методами (например, суммы Римана). Никаких продвинутых статистических знаний не требуется. Для получения более подробной информации по этим темам, пожалуйста,смотрите Gelman et al. (2013) и Blitzstein & Hwang (2014) вместе с соответствующими ссылками в них.

Схема статьи такова. В §2 я даю краткий обзор байесовского вывода и апостериорных распределений. В §3 я обсуждаю, для чего используются апостериоры на практике,

уделяя особое внимание интеграции и маргинализации. В §4 я описываю базовую схему аппроксимации этих апостериорных интегралов с использованием дискретных сеток. В §5 я иллюстрирую, как методы Монте-Карло становятся естественным продолжением подходов, основанных на сетке. В §6 я обсуждаю, как методы МСМС вписываются в более широкий спектр возможных подходов и их преимущества и недостатки. В §7 я исследую общие проблемы, с которыми сталкиваются методы МСМС. В §8 я исследую, как эти концепции сочетаются на практике, используя простой пример. Я завершаю в §9.

2 Bayesian Inference

Во многих научных приложениях у нас есть доступ к некоторым данным \mathbf{D} , которые мы хотим использовать, чтобы делать выводы об окружающем нас мире. Чаще всего мы хотим интерпретировать эти данные в свете лежащего в их основе *model* M , который может делать прогнозы относительно данных, которые мы ожидаем увидеть, как функцию некоторых параметров Θ_M этой конкретной модели.

Мы можем объединить эти части вместе, чтобы оценить вероятность $P(\mathbf{D}|\Theta_M, M)$ что мы действительно увидим те данные \mathbf{D} , которые мы собрали условно (т.е. предполагая) конкретного выбора параметров Θ_M из нашей модели M . Другими словами, если предположить, что наша модель M верна и параметры Θ_M описывают данные, то какова вероятность $P(\mathbf{D}|\Theta_M, M)$ параметров Θ_M на основе наблюдаемых данных \mathbf{D} ? Предполагая различные значения Θ_M дадут различные вероятности, говоря нам о том, какие варианты параметров лучше всего описывают наблюдаемые данные.

В байесовском выводе нас интересует вывод перевернутой величины, $P(\Theta_M|\mathbf{D}, M)$. Это описывает вероятность того, что лежащие в основе параметры на самом деле являются Θ_M , учитывая наши данные \mathbf{D} и предполагая определенную модель M . Используя факторизацию вероятности, мы можем связать эту новую вероятность $P(\Theta_M|\mathbf{D}, M)$ с вероятностью $P(\mathbf{D}|\Theta_M, M)$, описанной выше, как

$$P(\Theta_M|\mathbf{D}, M)P(\mathbf{D}|M) = P(\Theta_M, \mathbf{D}|M) = P(\mathbf{D}|\Theta_M, M)P(\Theta_M|M) \quad (1)$$

где $P(\Theta_M, \mathbf{D}|M)$ представляет собой совместную вероятность иметь базовый набор параметров Θ_M , описывающих данные, и наблюдать конкретный набор данных \mathbf{D} , которые мы уже собрали.

Перестановка этого равенства в более удобную форму дает нам теорему Бэйса:

$$P(\Theta_M|\mathbf{D}, M) = \frac{P(\mathbf{D}|\Theta_M, M)P(\Theta_M|M)}{P(\mathbf{D}|M)} \quad (2)$$

Теперь это уравнение точно описывает, как наши две вероятности соотносятся друг с другом.

$P(\Theta_M|M)$ часто упоминается как *предшествующий*. Это описывает вероятность наличия определенного набора значений Θ_M для нашей данной модели M до обработки наших данных. Поскольку это не зависит от данных, этот термин часто интерпретируется как представляющий наши ‘предшествующие убеждения’ о том, какими должны

быть Θ_M на основе предыдущих измерений, физических проблем и других известных факторов. На практике это приводит к существенному "дополнению" данных другой информацией.

Знаменатель

$$P(\mathbf{D}|M) = \int P(\mathbf{D}|\Theta_M, M)P(\Theta_M|M)d\Theta_M \quad (3)$$

называется доказательством или предельным правдоподобием для нашей модели M маргинально (т.е. интегрировано) по всем возможным значениям параметров Θ_M . В широком смысле, это попытка количественно оценить, насколько хорошо наша модель M объясняет данные \mathbf{D} после усреднения по всем возможным значениям Θ_M истинных базовых параметров. Другими словами, если наблюдения, предсказанные нашей моделью, похожи на данные \mathbf{D} , то M - хорошая модель. Модели, в которых это верно чаще всего, также предпочтительнее моделей, которые дают отличное согласие время от времени, но большую часть времени расходятся. Поскольку в большинстве случаев мы принимаем \mathbf{D} как данность, это часто оказывается константой.

Наконец, $P(\Theta_M|\mathbf{D}, M)$ представляет собой наше постериорное распределение. Это количественная оценка нашей веры в Θ_M после объединения нашей предварительной интуиции $P(\Theta_M|M)$ с текущими наблюдениями $P(\mathbf{D}|\Theta_M, M)$ и нормализации по общему доказательству $P(\mathbf{D}|M)$. Постериор будет представлять собой некоторый компромисс между предшествующим и вероятностью, причем точное сочетание зависит от силы и свойств предшествующего и качества данных, используемых для получения вероятности. Схематичная иллюстрация показана на [Figure 1](#).

Во всей остальной части статьи я буду писать эти четыре термина (вероятность, предшествующее (приор), доказательство, последующее (апостериор)), используя сокращенные обозначения, такие как

$$\mathcal{P}(\Theta) \equiv \frac{\mathcal{L}(\Theta)\pi(\Theta)}{\int \mathcal{L}(\Theta)\pi(\Theta)d\Theta} \equiv \frac{\mathcal{L}(\Theta)\pi(\Theta)}{\mathcal{Z}} \quad (4)$$

где $\mathcal{P}(\Theta) \equiv P(\Theta_M|\mathbf{D}, M)$ - апостериор, $\mathcal{L}(\Theta) \equiv P(\mathbf{D}|\Theta_M, M)$ - вероятность, $\pi(\Theta) \equiv P(\Theta_M|M)$ - приоритет, и константа $\mathcal{Z} \equiv P(\mathbf{D}|M)$ - доказательство. Для удобства я опустил обозначения модели M и данных \mathbf{D} , поскольку в большинстве случаев данные и модель считаются фиксированными, но при необходимости я буду вводить их снова.

Прежде чем продолжить, я хотел бы подчеркнуть, что интерпретация любого результата хороша лишь настолько, насколько хороши модели и приорные оценки, которые лежат в их основе. Попытки исследовать последствия той или иной модели с помощью, например, некоторых методов, описанных в этой статье, по сути, являются второстепенной задачей по сравнению с построением разумной модели с хорошо мотивированными приматами в первую очередь. Я настоятельно рекомендую читателям помнить об этой идее на протяжении всей оставшейся части этой работы.

Упражнение: Среднее значение шума

Настройка

Рассмотрим случай, когда у нас есть станции мониторинга температуры, расположенные по всему городу. Каждая станция i проводит зашумленное измерение \hat{T}_i темпера-

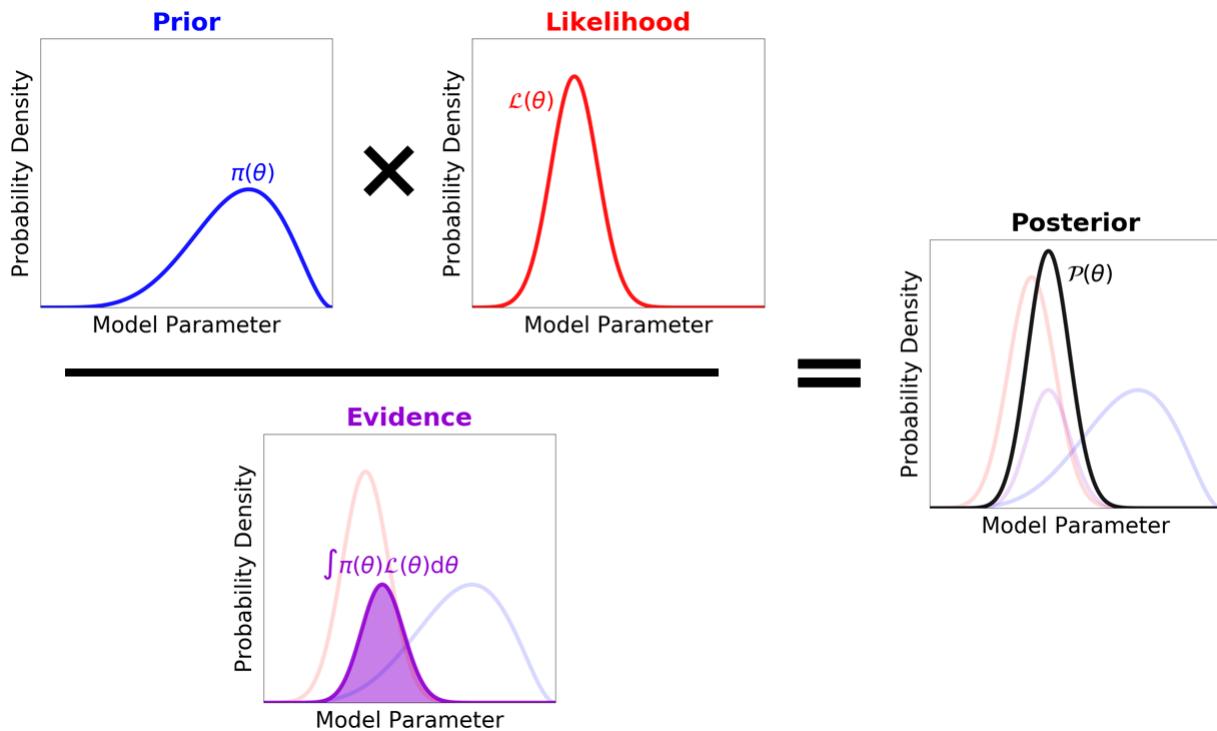


Рис. 1: Иллюстрация теоремы Байеса. Постериорная вероятность $\mathcal{P}(\Theta)$ (черный) параметров нашей модели Θ основана на комбинации наших предварительных убеждений $\pi(\Theta)$ (синий) и вероятности $\mathcal{L}(\Theta)$ (красный), нормированной на общее доказательство $\mathcal{Z} = \int \pi(\Theta) \mathcal{L}(\Theta) d\Theta$ (фиолетовый) для нашей конкретной модели. Дополнительные подробности см. в §2.

туры в любой день с некоторым шумом измерения σ_i . Мы будем считать, что наши измерения \hat{T}_i следуют нормальному (т.е. гауссовскому) распределению со средним T и стандартным отклонением σ_i , таким, что

$$\hat{T}_i \sim \mathcal{N}[T, \sigma_i]$$

Это означает, что вероятность

$$P(\hat{T}_i|T, \sigma_i) \equiv \mathcal{N}[T, \sigma_i] = \frac{1}{\sqrt{2\pi\sigma_i^2}} \exp\left[-\frac{1}{2} \frac{(\hat{T}_i - T)^2}{\sigma_i^2}\right]$$

для каждого наблюдения и

$$P(\{\hat{T}_i\}_{i=1}^n|T, \{\sigma_i\}_{i=1}^n) = \prod_{i=1}^n P(\hat{T}_i|T, \sigma_i)$$

для набора из n наблюдений.

Предположим, что у нас есть пять независимых шумных измерений температуры (в градусах Цельсия) с нескольких станций мониторинга

$$\hat{T}_1 = 26.3, \hat{T}_2 = 30.2, \hat{T}_3 = 29.4, \hat{T}_4 = 30.1, \hat{T}_5 = 29.8$$

с соответствующими неопределенностями

$$\sigma_1 = 1.7, \sigma_2 = 1.8, \sigma_3 = 1.2, \sigma_4 = 0.5, \sigma_5 = 1.3$$

Рассматривая исторические данные, мы обнаруживаем, что типичная базовая температура T в течение подобных дней имеет примерно нормальное распределение со средним значением $T_{\text{prior}} = 25$ и вариацией $\sigma_{\text{prior}} = 1.5$:

$$T \sim \mathcal{N}[T_{\text{prior}} = 25, \sigma_{\text{prior}} = 1.5]$$

Постановка проблемы

Используя эти предположения, вычислите:

1. приор $\pi(T)$,
2. вероятность $\mathcal{L}(T)$, и
3. апостериор $\mathcal{P}(T)$.

учитывая наши наблюдаемые данные $\{\hat{T}_i\}$ и ошибки $\{\sigma_i\}$ в диапазоне температур T . Как различаются эти три условия? Похоже ли предварительное предположение на хорошее? Почему или почему нет?

3 Для чего нужны апостериорные распределения?

Выше я описал, как теорема Байеса способна объединить наши предварительные убеждения и наблюдаемые данные в новую апостериорную оценку $\mathcal{P}(\Theta) \propto \mathcal{L}(\Theta)\pi(\Theta)$. Однако это только половина проблемы. Получив апостериор, мы должны затем использовать его, чтобы сделать выводы об окружающем нас мире. В целом, способы, которыми мы хотим использовать апостериоры, делятся на несколько широких категорий:

1. Сделать обоснованные предположения: сделать обоснованное предположение о том, какие параметры лежат в основе модели.
2. Квантование неопределенности: определить ограничения на диапазон возможных значений параметров модели.
3. Генерирование прогнозов: предельная оценка неопределенности параметров модели для предсказания наблюдаемых или других переменных, зависящих от параметров модели.
4. Сравнение моделей: использование доказательств, полученных с помощью различных моделей, для определения того, какая модель более благоприятна.

Для достижения этих целей нам часто интереснее попытаться использовать апостериор для оценки различных ограничений на сами параметры Θ или другие величины $f(\Theta)$, которые могут быть основаны на них. Это часто зависит от маргинализации неопределенностей, характеризуемых нашим апостериором (через правдоподобие и приоритет). Доказательство \mathcal{Z} , например, снова является просто интегралом правдоподобия и предшествования по всем возможным параметрам:

$$\mathcal{Z} = \int \mathcal{L}(\Theta)\pi(\Theta)d\Theta \equiv \int \tilde{\mathcal{P}}(\Theta)d\Theta \quad (5)$$

где $\tilde{\mathcal{P}}(\Theta) \equiv \mathcal{L}(\Theta)\pi(\Theta)$ это ненормированный апостериор.

Аналогично, если мы изучаем поведение подмножества "интересных" параметров Θ_{int} из $\Theta = \{\Theta_{\text{int}}, \Theta_{\text{nuis}}\}$, мы хотим маргинализировать поведение оставшихся "неприятных" параметров Θ_{nuis} , чтобы увидеть, как они могут повлиять на Θ_{int} . Этот процесс довольно прост, если известно все апостериорное значение Θ :

$$\mathcal{P}(\Theta_{\text{int}}) = \int \mathcal{P}(\Theta_{\text{int}}, \Theta_{\text{nuis}}) d\Theta_{\text{nuis}} = \int \mathcal{P}(\Theta) d\Theta_{\text{nuis}} \quad (6)$$

Другие величины, как правило, могут быть получены из значения ожидания различных функций $f(\Theta)$, зависящих от параметров, по отношению к апостериору:

$$\mathbb{E}_{\mathcal{P}} [f(\Theta)] \equiv \frac{\int f(\Theta)\mathcal{P}(\Theta)d\Theta}{\int \mathcal{P}(\Theta)d\Theta} = \frac{\int f(\Theta)\tilde{\mathcal{P}}(\Theta)d\Theta}{\int \tilde{\mathcal{P}}(\Theta)d\Theta} = \int f(\Theta)\mathcal{P}(\Theta)d\Theta \quad (7)$$

поскольку $\int \mathcal{P}(\Theta)d\Theta = 1$ по определению и $\tilde{\mathcal{P}}(\Theta) \propto \mathcal{P}(\Theta)$. Это представляет собой средневзвешенное значение $f(\Theta)$, где при каждом значении Θ мы взвешиваем полученное значение $f(\Theta)$, исходя из вероятности того, что это значение является правильным.

В совокупности мы видим, что почти во всех случаях нам интереснее вычислять интегралы по апостериору, чем знать сам апостериор. Другими словами, апостериор редко бывает полезен сам по себе; в основном он становится полезным при интегрировании по нему.

Это различие между оценкой ожиданий и других интегралов по апостериору и оценкой апостериора как такового является ключевым элементом байесовского вывода. Это различие имеет огромное значение, когда дело доходит до практического выполнения выводов, поскольку часто бывает так, что мы можем получить отличную оценку $\mathbb{E}_{\mathcal{P}}[f(\Theta)]$, даже если у нас крайне плохая оценка $\mathcal{P}(\Theta)$ или $\tilde{\mathcal{P}}(\Theta)$.

Ниже приводится более подробная информация, чтобы проиллюстрировать, как конкретные категории, описанные выше, превращаются в конкретные интегралы по (ненормированному) заднему числу. Пример показан на [Figure 2](#).

3.1 Делаем обоснованные предположения

Один из основных постулатов байесовского вывода состоит в том, что мы не знаем ни истинной модели M_* , ни ее истинных базовых параметров Θ_* , характеризующих наблюдаемые данные: имеющаяся у нас модель M почти всегда является упрощением того, что происходит на самом деле. Однако если мы предположим, что наша текущая модель M верна, то мы можем попытаться использовать наш апостериор $\mathcal{P}(\Theta)$, чтобы предложить точечную оценку $\hat{\Theta}$, которая, по нашему мнению, является довольно хорошим предположением для истинного значения Θ_* .

Что именно считается “хорошим”? Это зависит от того, что именно нас волнует. В общем случае, мы можем оценить “хорошо”, задав противоположный вопрос: насколько сильно мы наказаны, если наша оценка $\hat{\Theta} \neq \Theta_*$ окажется неверной? Часто для этого используется функция потерь $L(\hat{\Theta}|\Theta_*)$, которая наказывает нас, когда наша точечная оценка $\hat{\Theta}$ отличается от Θ_* . Примером общей функции потерь является $L(\hat{\Theta}|\Theta_*) = |\hat{\Theta} - \Theta_*|^2$ (т.е. квадратичная потеря), где неправильное предположение наказывается квадратом величины расхождения между предположением $\hat{\Theta}$ и истинным значением Θ_* .

К сожалению, мы не знаем, каково реальное значение Θ_* , чтобы оценить истинный проигрыш. Однако мы можем поступить следующим образом и вычислить ожидаемый убыток, усредненный по всем возможным значениям Θ_* , основываясь на нашем апостериоре:

$$L_{\mathcal{P}}(\hat{\Theta}) \equiv \mathbb{E}_{\mathcal{P}} [L(\hat{\Theta}|\Theta)] = \int L(\hat{\Theta}|\Theta) \mathcal{P}(\Theta) d\Theta \quad (8)$$

Тогда разумным выбором для $\hat{\Theta}$ будет значение, которое минимизирует этот ожидаемый убыток вместо фактического (неизвестного) убытка:

$$\hat{\Theta} \equiv \underset{\Theta'}{\operatorname{argmin}} [L_{\mathcal{P}}(\Theta')] \quad (9)$$

где argmin указывает на значение (аргумент) Θ' , которое минимизирует ожидаемый убыток $L_{\mathcal{P}}(\Theta')$.

Хотя эта стратегия может работать для любой произвольной функции потерь, решение $\hat{\Theta}$ часто требует использования численных методов и повторного интегрирования по

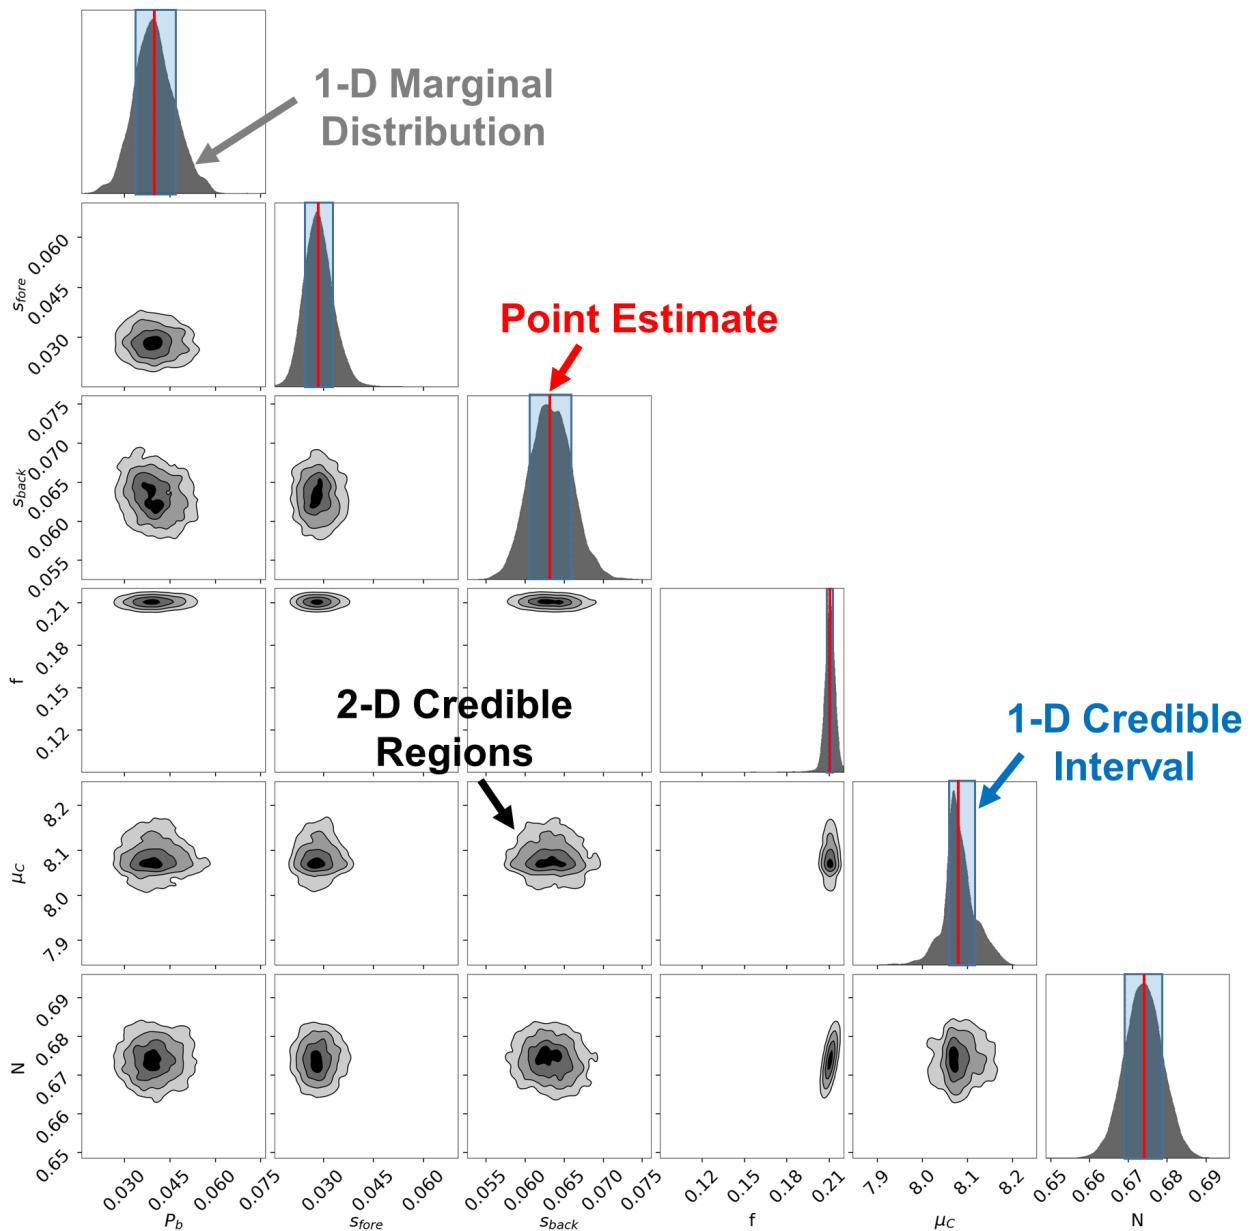


Рис. 2: Угловой график, показывающий пример практического использования астериоров. На каждой из верхних панелей показано одномерное маргинальное апостериорное распределение для каждого параметра (серый), а также соответствующие медианные точечные оценки (красный) и 68%-ные доверительные интервалы (синий). На каждой центральной панели показаны 10%, 40%, 65% и 85% доверительные области для каждого двумерного маргинального апостериорного распределения. Дополнительные сведения см. в разделе §3.

$\mathcal{P}(\Theta)$. Однако для определенных функций потерь существуют аналитические решения. Например, легко показать (и это будет интересным упражнением для заинтересованного читателя), что оптимальная оценка точки $\hat{\Theta}$ при квадратичных потерях - это просто среднее.

3.2 Quantifying Uncertainty

Во многих случаях нас интересует не просто вычисление предсказания $\hat{\Theta}$ для Θ_* , но и ограничение области $\mathcal{C}(\Theta)$ возможных значений, внутри которой Θ_* может лежать с некоторой долей уверенности. Другими словами, можем ли мы построить область \mathcal{C}_X такую, что мы считаем, что существует $X\%$ шанс, что она содержит Θ_* ?

Существует множество возможных определений этой вероятной области. Одно из общих определений - это область выше некоторого порога апостериорности \mathcal{P}_X , в которой содержится $X\%$ апостериорности, т.е. где

$$\int_{\Theta \in \mathcal{C}_X} \mathcal{P}(\Theta) d\Theta = \frac{X}{100} \quad (10)$$

с учетом

$$\mathcal{C}_X \equiv \{\Theta : \mathcal{P}(\Theta) \geq \mathcal{P}_X\} \quad (11)$$

Другими словами, мы хотим проинтегрировать наш астериориор по всем Θ , где значение $\mathcal{P}(\Theta) > \mathcal{P}_X$ больше некоторого порога \mathcal{P}_X , где \mathcal{P}_X задается так, чтобы этот интеграл охватывал $X\%$ от полного астериориора. Обычно для X выбирают 68% и 95% (т.е. "1-сигма" и "2-сигма" доверительные интервалы).

В частном случае, когда наше (маргинальное) апостериори является одномерным, достоверные интервалы часто определяются с помощью перцентилей, а не порогов, где место x_p расположения p -го перцентиля определяется как

$$\int_{-\infty}^{x_p} \mathcal{P}(x) dx = \frac{p}{100} \quad (12)$$

Мы можем использовать их для определения достоверной области $[x_{\text{low}}, x_{\text{high}}]$, содержащей $Y\%$ данных, взяв $x_{\text{low}} = x_{(1-Y)/2}$ и $x_{\text{high}} = x_{(1+Y)/2}$. Хотя это приводит к асимметричным пороговым значениям и не обобщается на более высокие размерности, преимуществом этого метода является то, что он всегда охватывает медианное значение x_{50} и имеет равные хвостовые вероятности (т. е. $(1 - Y)/2\%$ апостериорного значения с каждой стороны).

В целом, когда в тексте упоминаются "достоверные интервалы", следует исходить из определения перцентиля, если явно не указано иное.

3.3 Предсказание

Помимо попыток оценить основные параметры нашей модели, мы также часто хотим сделать предсказания других наблюдений или переменных, которые зависят от параметров нашей модели. Если мы считаем, что знаем истинные базовые параметры модели

Θ_* , то этот процесс прост. Однако, учитывая, что у нас есть доступ только к апостериорному распределению $P(\Theta)$ по возможным значениям Θ_* , чтобы предсказать, что произойдет, нам нужно сделать маргинализацию на эту неопределенность.

Мы можем количественно выразить эту интуицию с помощью апостериорного прогноза $P(\tilde{\mathbf{D}}|\mathbf{D})$, который представляет собой вероятность увидеть новые данные $\tilde{\mathbf{D}}$ на основе имеющихся данных \mathbf{D} :

$$P(\tilde{\mathbf{D}}|\mathbf{D}) \equiv \int P(\tilde{\mathbf{D}}|\Theta)P(\Theta|\mathbf{D})d\Theta \equiv \int \tilde{\mathcal{L}}(\Theta)\mathcal{P}(\Theta)d\Theta = \mathbb{E}_{\mathcal{P}} [\tilde{\mathcal{L}}(\Theta)] \quad (13)$$

Другими словами, для гипотетических данных $\tilde{\mathbf{D}}$ мы хотим вычислить ожидаемое значение вероятности $\tilde{\mathcal{L}}(\Theta)$ по всем возможным значениям Θ на основе текущего апостериорного $\mathcal{P}(\Theta)$.

3.4 Сравнение моделей

Последний момент, представляющий интерес во многих байесовских анализах, - это попытка выяснить, благоприятствуют ли данные какой-либо модели (моделям), которую мы предполагаем в нашем анализе. Наш выбор приора или конкретный способ параметризации данных может привести к существенным различиям в интерпретации результатов.

Мы можем сравнить две модели, вычислив коэффициент Bayes factor:

$$\mathcal{R}_2^1 \equiv \frac{P(M_1|\mathbf{D})}{P(M_2|\mathbf{D})} = \frac{P(\mathbf{D}|M_1)P(M_1)}{P(\mathbf{D}|M_2)P(M_2)} \equiv \frac{\mathcal{Z}_1 \pi_1}{\mathcal{Z}_2 \pi_2} \quad (14)$$

где \mathcal{Z}_M - снова доказательства в пользу модели M , а π_M - наша предварительная вера в то, что M верна по сравнению с конкурирующей моделью. В совокупности, фактор Байеса \mathcal{R} говорит нам, насколько конкретная модель предпочтительнее другой, учитывая наблюдаемые данные, предельные значения всех возможных параметров модели Θ_M и нашу предыдущую относительную уверенность в модели.

Еще раз отметим, что вычисление \mathcal{Z}_M требует вычисления интеграла $\int \tilde{\mathcal{P}}(\Theta)d\Theta$ от ненормированного заднего числа $\tilde{\mathcal{P}}(\Theta)$ по Θ . В сочетании с другими примерами, описанными в этом разделе, становится ясно, что многие распространенные случаи использования байесовского анализа основаны на вычислении интегралов по (возможно, ненормированному) апостериору.

Упражнение: Пересмотр шумного значения

Setup

Вернемся к нашему температурному апостериору $\mathcal{P}(T)$ из §2. Мы хотим использовать этот результат для получения интересных оценок и ограничений на возможную базовую температуру T .

Точечные оценки

mean можно определить как точечную оценку $\hat{\Theta}$, которая минимизирует ожидаемые потери $L_{\mathcal{P}}(\hat{\Theta})$ при квадратичных потерях:

$$L_{\text{mean}}(\hat{\Theta}|\Theta_*) = |\hat{\Theta} - \Theta_*|^2$$

median может быть определена как точечная оценка, которая минимизирует $L_{\mathcal{P}}(\hat{\Theta})$ при абсолютных потерях:

$$L_{\text{med}}(\hat{\Theta}|\Theta_*) = |\hat{\Theta} - \Theta_*|$$

mode можно определить как точечную оценку, которая минимизирует $L_{\mathcal{P}}(\hat{\Theta})$ при ‘катастрофических’ потерях:

$$L_{\text{mode}}(\hat{\Theta}|\Theta_*) = -\delta(|\hat{\Theta} - \Theta_*|)$$

где $\delta(\cdot)$ - дельта-функция Дирака, определенная так, что

$$\int f(x)\delta(x-a)dx = f(a)$$

Учитывая эти выражения для среднего, медианы и моды, оцените соответствующие оценки температурных точек T_{mean} , T_{med} и T_{mode} из нашего соответствующего постера. Не стесняйтесь экспериментировать с различными аналитическими и численными методами для выполнения этих расчетов.

Мы можем ожидать, что исторические данные, которые мы использовали для наших приор, могут не так хорошо работать сегодня, если произошли некоторые долгосрочные изменения в средней температуре. Например, мы ожидаем, что средняя температура со временем увеличилась, и поэтому мы, возможно, не захотим штрафовать более жаркие температуры $T \geq T_{\text{prior}}$ так же сильно, как более холодные $T < T_{\text{prior}}$. Мы можем закодировать эту информацию в асимметричной функции потерь, например

$$L(\hat{T}|T_*) = \begin{cases} |\hat{T} - T_*|^3 & T < T_{\text{prior}} \\ |\hat{T} - T_*| & T \geq T_{\text{prior}} \end{cases}$$

Какова оптимальная точечная оценка T_{asym} , которая минимизирует ожидаемые потери в этом случае?

Достоверные интервалы

Далее попробуем количественно оценить неопределенность. Учитывая апостериор $\mathcal{P}(T)$, вычислите 50%, 80% и 95% доверительных интервалов, используя апостериорные пороги \mathcal{P}_X . Затем вычислите эти доверительные интервалы с помощью перцентилей. Есть ли различия между доверительными интервалами, вычисленными двумя методами? Почему или почему нет?

Апостериорное предсказание

Чтобы распространить наши неопределенности на следующие наблюдения, вычислим апостериорное предсказание $P(\hat{T}_6 | \{\hat{T}_1, \dots, \hat{T}_5\})$ по диапазону возможных измерений температуры \hat{T}_6 для следующих наблюдений с учетом предыдущих пяти $\{\hat{T}_1, \dots, \hat{T}_5\}$, предполагая неопределенность $\sigma_6 = 0$, $\sigma_6 = 0.5$, и $\sigma_6 = 2$.

Сравнение моделей

Наконец, мы хотим выяснить, является ли наша предварительная оценка хорошим предположением. Используя численные методы, вычислите доказательство \mathcal{Z} для нашего приоритета по умолчанию со средним $T_{\text{prior}} = 25$ и стандартным отклонением $\sigma_{\text{prior}} = 1.5$. Затем сравните их с доказательствами, полученными на основе альтернативного приоритета, где мы предполагаем, что температура выросла примерно на пять Сравнение моделей градусов со средним $T_{\text{prior}} = 30$, но с соответствующей большей неопределенностью $\sigma_{\text{prior}} = 3$. Является ли одна модель особенно предпочтительной по сравнению с другой?

4 Апроксимация апостериорных интегралов с помощью сеток

Теперь я хочу изучить методы оценки апостериорных интегралов. Хотя в некоторых случаях (например, в случае сопряженных приоров) их можно вычислить аналитически, в общем случае это не так. Поэтому для правильной оценки величин, подобных тем, что описаны в §3, необходимо использовать численные методы (освещенные в предыдущих упражнениях).

Для начала я рассмотрю случай, когда наш интеграл по Θ является одномерным. В этом случае мы можем аппроксимировать его с помощью стандартных численных методов, таких как сумма Римана по дискретной сетке точек:

$$\mathbb{E}_{\mathcal{P}} [f(\Theta)] = \int f(\Theta) \mathcal{P}(\Theta) d\Theta \approx \sum_{i=1}^n f(\Theta_i) \mathcal{P}(\Theta_i) \Delta\Theta_i \quad (15)$$

где

$$\Delta\Theta_i = \Theta_{j+1} - \Theta_j \quad (16)$$

это просто расстояние между множеством точек $j = 1, \dots, n + 1$ на базовой сетке и

$$\Theta_i = \frac{\Theta_{j+1} + \Theta_j}{2} \quad (17)$$

определяется как средняя точка между это просто расстояние между множеством точек $j = 1, \dots, n + 1$ на базовой сетке и Θ_j и Θ_{j+1} .¹ Как показано на Figure 3, этот подход сродни попытке аппроксимировать интеграл с помощью дискретного набора n прямоугольников с высотой $f(\Theta_i) \mathcal{P}(\Theta_i)$ и шириной $\Delta\Theta_i$.

¹Выбор Θ_i в качестве одной из конечных точек дает последовательное поведение (см. §4.3) при увеличении числа точек сетки $n \rightarrow \infty$, но обычно приводит к большим погрешностям при конечном n .

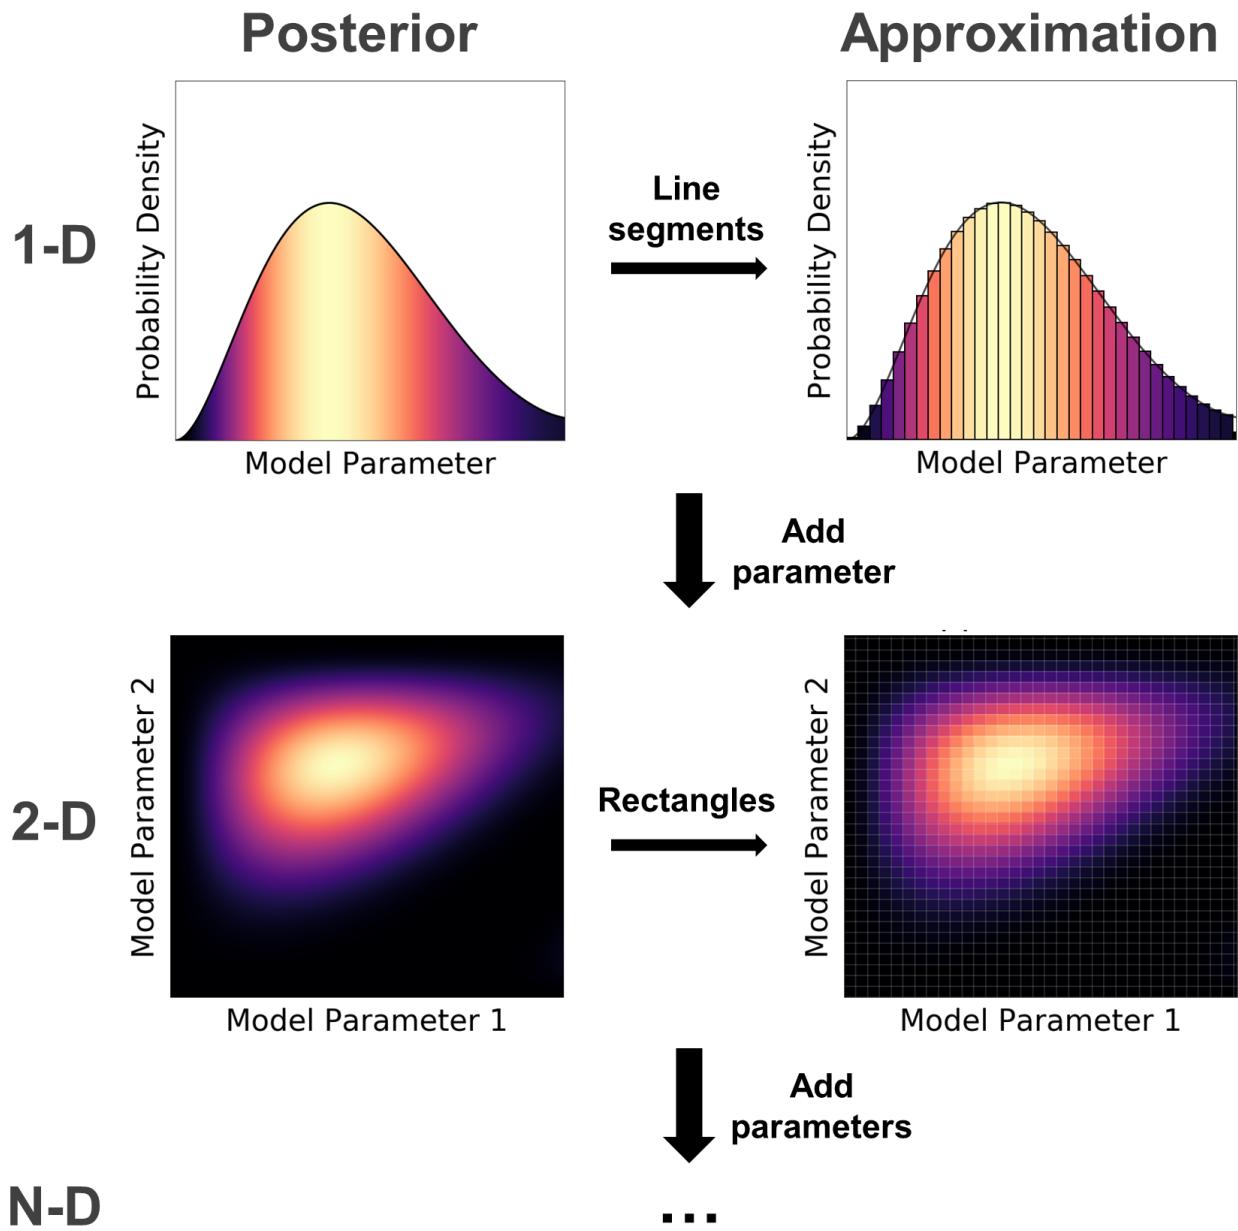


Рис. 3: Иллюстрация того, как аппроксимировать апостериорные интегралы с помощью дискретной сетки точек. Мы разбиваем апостериор на смежные области, определяемые позицией Θ_i (например, конечной или средней точкой) с соответствующей плотностью $\mathcal{P}(\Theta_i)$ и объемом $\Delta\Theta_i$ по сетке с $i = 1, \dots, n$ элементами. Наш интеграл может быть аппроксимирован сложением каждой из этих областей пропорционально задней массе $\mathcal{P}(\Theta_i) \times \Delta\Theta_i$, содержащейся в ней. В одномерном пространстве (вверху) эти элементы объема $\Delta\Theta_i$ соответствуют отрезкам прямых, а в двухмерном (в середине) - прямоугольникам. Это можно обобщить на более высокие измерения (внизу), где мы вместо этого использовали N-D кубоиды. Дополнительные подробности см. в разделе §4.

Эту идею можно обобщить на более высокие измерения. В этом случае вместо разбиения интеграла на n одномерных сегментов мы можем разложить его на множество n N-D кубоидов. Тогда вклад каждого из этих кубоидов пропорционален произведению "высоты" $f(\Theta_i)\mathcal{P}(\Theta_i)$ и объема

$$\Delta\Theta_i = \prod_{j=1}^d \Delta\Theta_{i,j} \quad (18)$$

где $\Delta\Theta_{i,j}$ - ширина i -го кубоида в j -м измерении. См. [Figure 3](#) для наглядного представления этой процедуры.

Подставив $\mathcal{P}(\Theta) = \tilde{\mathcal{P}}(\Theta)/\mathcal{Z}$ в значение ожидания и заменив все интегралы их приближениями на основе сетки, получим:

$$\mathbb{E}_{\mathcal{P}}[f(\Theta)] = \frac{\int f(\Theta)\mathcal{P}(\Theta)d\Theta}{\int \mathcal{P}(\Theta)d\Theta} = \frac{\int f(\Theta)\tilde{\mathcal{P}}(\Theta)d\Theta}{\int \tilde{\mathcal{P}}(\Theta)d\Theta} \approx \frac{\sum_{i=1}^n f(\Theta_i)\tilde{\mathcal{P}}(\Theta_i)\Delta\Theta_i}{\sum_{i=1}^n \tilde{\mathcal{P}}(\Theta_i)\Delta\Theta_i} \quad (19)$$

Обратите внимание, что знаменатель теперь представляет собой оценку доказательств:

$$\mathcal{Z} = \int \tilde{\mathcal{P}}(\Theta)d\Theta \approx \sum_{i=1}^n \tilde{\mathcal{P}}(\Theta_i)\Delta\Theta_j \quad (20)$$

Эта замена ненормированного апостериорного $\tilde{\mathcal{P}}(\Theta)$ на апостериорное $\mathcal{P}(\Theta)$ является важной частью вычисления ожидаемых значений на практике, поскольку мы можем вычислить $\tilde{\mathcal{P}}(\Theta) = \mathcal{L}(\Theta)\pi(\Theta)$ непосредственно без знания \mathcal{Z} .

4.1 Проклятие размерности

Хотя этот подход прост, он имеет один непосредственный и серьезный недостаток: общее количество точек сетки увеличивается экспоненциально с ростом числа измерений. Например, если предположить, что у нас есть примерно $k \geq 2$ точек сетки в каждом измерении, то общее количество точек n в нашей сетке увеличивается как

$$n \sim \prod_{j=1}^d k = k^d \quad (21)$$

Это означает, что даже в абсолютном лучшем случае, когда $k = 2$, мы имеем масштабирование 2^d .

Это ужасное масштабирование часто называют проклятием размерности. Эта экспоненциальная зависимость оказывается общим свойством высокоразмерных распределений (т.е. апостериоров моделей с большим числом параметров), к которому я вернусь позже в §7.

4.2 Эффективный размер выборки

Помимо экспоненциального масштабирования размерности, у использования сеток есть и более тонкий недостаток. Поскольку мы не знаем форму распределения заранее, вклад

каждой части сетки (т.е. каждого N-D кубоида) может быть крайне неравномерным в зависимости от структуры сетки. Другими словами, эффективность этого подхода зависит не только от количества точек сетки n , но и от места их распределения. Если мы плохо определим точки сетки, мы можем получить много точек, расположенных в областях, где $\tilde{\mathcal{P}}(\Theta)$ и/или $f(\Theta)\tilde{\mathcal{P}}(\Theta)$ относительно малы. Это означает, что в их соответствующих суммах будет доминировать небольшое количество точек с гораздо большими относительными "весами". В идеале мы должны увеличить разрешение сетки в тех областях, где апостериорное значение велико, и уменьшить его в других местах, чтобы смягчить этот эффект.

Обратите внимание, что мы используем термин "веса" в предыдущем абзаце вполне осознанно. Если вспомнить нашу первоначальную аппроксимацию, то форма уравнения (19) очень похожа на ту, которая может быть использована для вычисления взвешенного выборочного среднего для $f(\Theta)$. В этом случае, когда у нас есть n наблюдений $\{f_1, \dots, f_n\}$ с соответствующими весами $\{w_1, \dots, w_n\}$, взвешенное среднее находится просто:

$$\hat{f}_{\text{mean}} \equiv \frac{\sum_{i=1}^n w_i f_i}{\sum_{i=1}^n w_i} \quad (22)$$

Действительно, если мы определим

$$f_i \equiv f(\Theta_i), \quad w_i \equiv \tilde{\mathcal{P}}(\Theta_i)\Delta\Theta_i \quad (23)$$

тогда связь между взвешенным выборочным средним в уравнении (22) и матожиданием от нашей сетки в уравнении (19) становится явной:

$$\mathbb{E}_{\mathcal{P}} [f(\Theta)] \approx \frac{\sum_{i=1}^n f(\Theta_i)\tilde{\mathcal{P}}(\Theta_i)\Delta\Theta_i}{\sum_{i=1}^n \tilde{\mathcal{P}}(\Theta_i)\Delta\Theta_i} \equiv \frac{\sum_{i=1}^n w_i f_i}{\sum_{i=1}^n w_i} \quad (24)$$

Рассматривая нашу сетку как набор образцов n , мы также можем рассмотреть соответствующий эффективный размер выборки (ESS) $n_{\text{eff}} \leq n$. В ESS заложена идея о том, что не все наши выборки несут одинаковое количество информации: если у нас есть n образцов, которые очень похожи друг на друга, мы ожидаем получить значительно худшую оценку, чем если у нас есть n образцов, которые сильно отличаются друг от друга. Это происходит потому, что информация в коррелированных выборках, по крайней мере, частично избыточна по отношению друг к другу, причем количество избыточности увеличивается с ростом силы корреляции: в то время как две независимые выборки предоставляют совершенно уникальную информацию о распределении и никакой информации друг о друге, две коррелированные выборки вместо этого представляют некоторую информацию друг о друге за счет основного распределения.

Возвращаясь к сеткам, это соответствие означает, что теоретически мы можем получить оценку матожидания $\mathbb{E}_{\mathcal{P}} [f(\Theta)]$, которая будет по крайней мере столь же хороша, как и та, которую мы могли бы иметь в настоящее время, используя меньшее число $n_{\text{eff}} \leq n$ точек сетки, если бы мы могли распределить их более эффективно. Это различие имеет значение, потому что ошибки в нашей оценке матожидания обычно масштабируются как функция n_{eff} , а не n . Например, ошибка среднего значения обычно составляет $\propto n_{\text{eff}}^{-1/2}$, а не $\propto n^{-1/2}$.

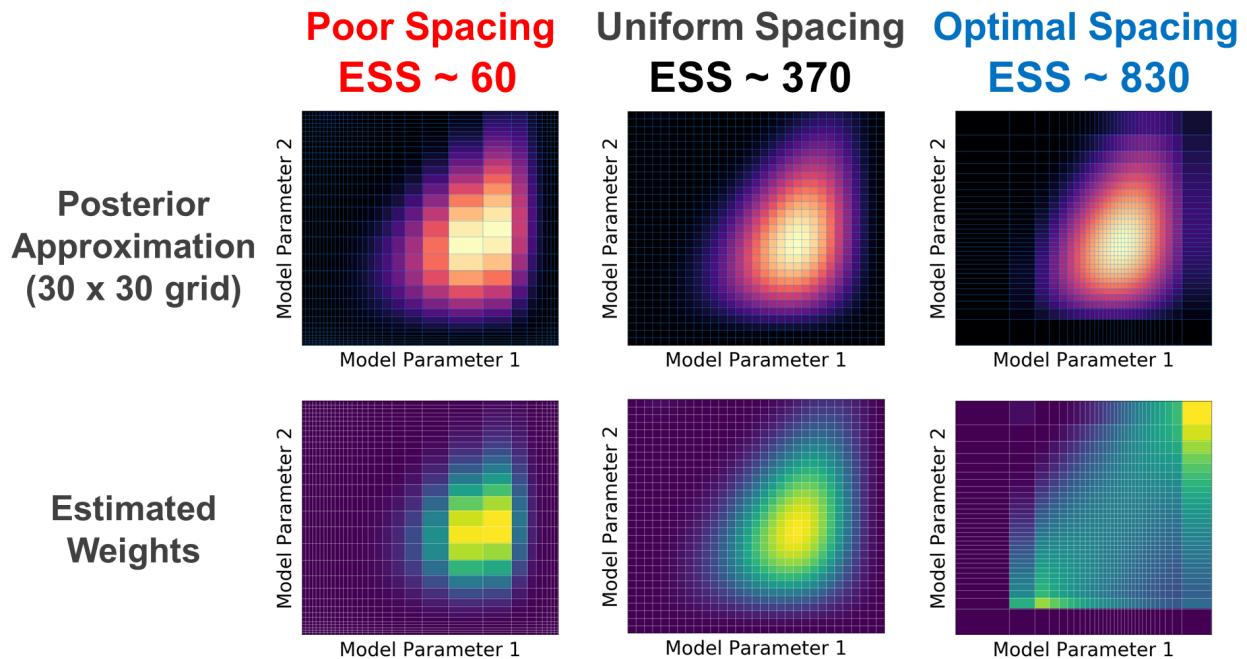


Рис. 4: Пример того, как изменение расстояния (элементов объема) сетки может кардинально повлиять на связанную с ней оценку апостериорных интегралов. На игрушечном двухмерном апостериорном интеграле $\mathcal{P}(\Theta)$ простое изменение расстояния между элементами соответствующей двухмерной сетки 30×30 резко влияет на эффективный размер выборки (ESS) (см. §4.2). Различия между плохим расстоянием (слева), равномерным расстоянием (в середине) и оптимальным расстоянием (справа) приводят к разнице в ESS на порядок величины, что видно по распределению весов (внизу), связанных с элементами объема каждой сетки. Дополнительные подробности см. в §4.2.

Мы можем количественно оценить идеи, лежащие в основе ESS, как обсуждалось выше, введя формальное определение, следуя Kish (1965):

$$n_{\text{eff}} \equiv \frac{\left(\sum_{i=1}^n w_i\right)^2}{\sum_{i=1}^n w_i^2} \quad (25)$$

В соответствии с нашей интуицией, наилучшим случаем при таком определении является тот, в котором все веса равны ($w_i = w$):

$$n_{\text{eff}}^{\text{best}} = \frac{\left(\sum_{i=1}^n w_i\right)^2}{\sum_{i=1}^n w_i^2} = \frac{(nw)^2}{\sum_{i=1}^n w^2} = \frac{n^2 w^2}{nw^2} = n \quad (26)$$

Аналогичным образом, наихудшим случаем является тот, когда весь вес сосредоточен вокруг одной выборки ($w_i = w$ для $i = j$ и $w_i = 0$ в противном случае):

$$n_{\text{eff}}^{\text{worst}} = \frac{\left(\sum_{i=1}^n w_i\right)^2}{\sum_{i=1}^n w_i^2} = \frac{(w)^2}{w^2} = 1 \quad (27)$$

В первом случае (при $n_{\text{eff}}^{\text{best}}$) каждый из элементов нашей сетки вносит примерно одинаковый вклад в интеграл, а во втором (при $n_{\text{eff}}^{\text{worst}}$) весь интеграл по существу содержится только в одной из областей N-D кубоида n . Иллюстрация такого поведения показана на Figure 4.

4.3 Сходимость и согласованность

Теперь, когда я обрисовал взаимосвязь между структурой нашей сетки и ESS, я хочу рассмотреть два последних вопроса: сходимость и согласованность. Сходимость - это идея о том, что, хотя наши оценки по n выборкам (точкам сетки) могут быть шумными, они приближаются к некоторому надежному значению по мере того, как $n \rightarrow \infty$:

$$\lim_{n \rightarrow \infty} \frac{\sum_{i=1}^n f(\Theta_i) \tilde{\mathcal{P}}(\Theta_i) \Delta \Theta_i}{\sum_{i=1}^n \tilde{\mathcal{P}}(\Theta_i) \Delta \Theta_i} = C \quad (28)$$

Последовательность - это впоследствии идея о том, что значение, к которому мы сходимся, является истинным значением, которое мы хотим оценить:

$$\lim_{n \rightarrow \infty} \frac{\sum_{i=1}^n f(\Theta_i) \tilde{\mathcal{P}}(\Theta_i) \Delta \Theta_i}{\sum_{i=1}^n \tilde{\mathcal{P}}(\Theta_i) \Delta \Theta_i} = \mathbb{E}_{\mathcal{P}} [f(\Theta)] \quad (29)$$

Легко показать, что если матожидание хорошо определено (т.е. существует) и сетка покрывает всю область Θ (т.е. охватывает наименьшие и наибольшие возможные значения в каждом измерении), то использование сетки является согласованным способом оценки матожидания. Это должно иметь интуитивный смысл: при условии, что наша сетка достаточно обширна в Θ , так что мы не "пропустим" ни одной области пространства параметров, мы должны быть в состоянии оценить $\mathbb{E}_{\mathcal{P}} [f(\Theta)]$ с произвольной точностью, просто увеличивая разрешение в $\Delta \Theta$.

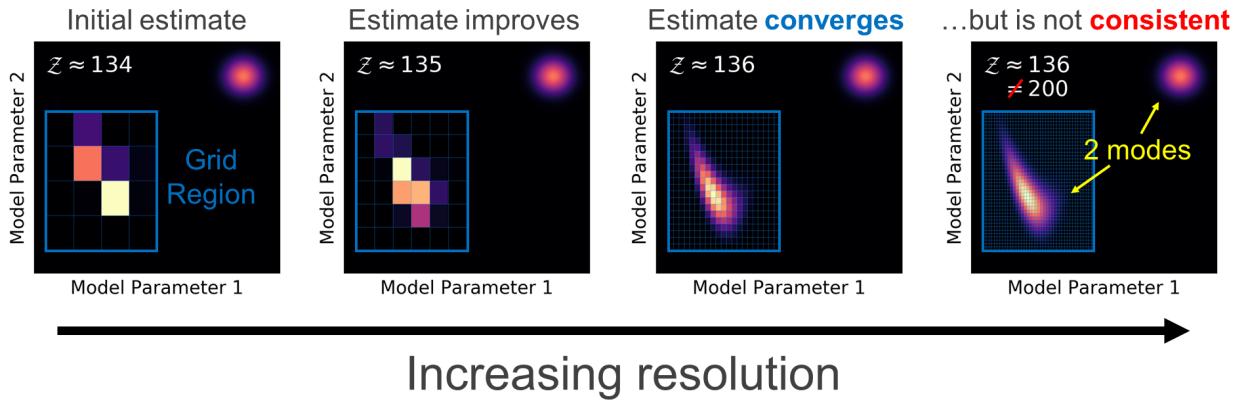


Рис. 5: Иллюстрация того, как оценки на основе сетки могут быть конвергентными (т.е. сходиться к одному значению по мере увеличения числа точек сетки), но не консистентными (т.е. значение, к которому они сходятся, не является правильным ответом). У нашего игрушечного двухмерного ненормированного апостериорного $\tilde{P}(\Theta)$ есть два режима, которые хорошо разделены с общим доказательством $Z = 200$. Если мы не знаем о втором режиме, мы можем определить область сетки, которая охватывает только подмножество всего пространства параметров (слева). Хотя увеличение разрешения сетки в этой области позволяет оценкам Z сходиться к единому ответу (слева направо), это не равно правильному ответу $Z = 200$, потому что мы пренебрегли вкладом другой компоненты (справа). Дополнительные подробности см. в §4.3

К сожалению, мы не знаем заранее, в каком диапазоне значений Θ должна находиться наша сетка. В то время как параметры могут лежать в диапазоне $(-\infty, +\infty)$, сетки опираются на элементы конечного объема, поэтому мы должны выбрать некоторое конечное подпространство для сетки. Поэтому, хотя сетки могут давать оценки, которые сходятся к некоторому значению в диапазоне, охватываемом точками сетки, всегда есть вероятность, что значительная часть апостериорного значения лежит за пределами этого диапазона. В таких случаях не гарантируется, что сетки будут последовательными оценщиками $\mathbb{E}_{\mathcal{P}}[f(\Theta)]$. Иллюстрация этой проблемы показана на [Figure 5](#). Этой фундаментальной проблеме не подвержены методы Монте-Карло, о которых я расскажу в §5.

Упражнение: Сетки над двумерным гауссовым пространством

Setup

Рассмотрим ненормированный апостериор, хорошо аппроксимируемый двумерным гауссовым (нормальным) распределением с центром на (μ_x, μ_y) со стандартными отклонениями (σ_x, σ_y) :

$$\tilde{\mathcal{P}}(x, y) = \exp \left\{ -\frac{1}{2} \left[\frac{(x - \mu_x)^2}{\sigma_x^2} + \frac{(y - \mu_y)^2}{\sigma_y^2} \right] \right\}$$

Предположим, что мы ожидаем найти, что наше апостериорное значение имеет среднее 0 и стандартное отклонение 1. Однако в действительности наше апостериорное значение имеет среднее $(\mu_x, \mu_y) = (-0.3, 0.8)$ и стандартное отклонение $(\sigma_x^2, \sigma_y^2) = (2.0, 5)$, имитируя обычный случай, когда наши предварительные ожидания и апостериорные выводы несколько расходятся.

Оценка на основе сетки

Мы хотим использовать двумерную сетку для оценки различных форм постреляционных интегралов. Начиная с равномерно расположенной сетки 5×5 из $[-2, 2]$, вычислите:

1. доказательства \mathcal{Z} ,
2. средние $\mathbb{E}_{\mathcal{P}}[x]$ и $\mathbb{E}_{\mathcal{P}}[y]$,
3. 68% доверительные интервалы (или ближайшее приближение) $[x_{\text{low}}, x_{\text{high}}]$ и $[y_{\text{low}}, y_{\text{high}}]$, элемент и эффективный размер выборки n_{eff} .

Насколько точно каждая из этих величин соответствует тем значениям, которые мы могли бы ожидать? Что говорит нам n_{eff}/n о том, насколько эффективно мы распределили точки сетки?

Конвергенция

Повторите упражнение, используя равномерно расположенную сетку из 20×20 точек и 100×100 точек. Прокомментируйте любые различия. Насколько повысилась общая точность? Сходятся ли оценки?

Консистенция

Далее расширьте границы сетки до $[-5, 5]$ и выполните то же упражнение, что и выше. Существенно ли изменились ответы? Если да, то что это говорит нам о согласованности наших предыдущих оценок? Регулируйте плотность и границы сетки до тех пор, пока ответы не станут сходящимися и непротиворечивыми. Помните, что мы не знаем точной формы апостериорных оценок заранее. Что из этого следует в отношении общих проблем при применении сеток на практике?

Эффективный размер выборки

Наконец, изучите, существует ли простая схема настройки расположения точек сетки x и y для максимизации эффективного размера выборки на основе определения, изложенного в §4.2. Если да, то можете ли вы объяснить, почему это работает? Если нет, то почему? Насколько адаптивная регулировка расстояния между сетками может улучшить n_{eff} и общую точность наших оценок по сравнению с эквивалентными равномерно распределенными сетками?

5 От сеток к методам Монте-Карло

5.1 Соединение точек сетки и выборок

Ранее я описал, как можно связать оценку $\mathbb{E}_{\mathcal{P}}[f(\Theta)]$ с помощью сетки из n точек с эквивалентной оценкой с помощью набора n выборок $\{f_1, \dots, f_n\}$ и ряда связанных с ними весов $\{w_1, \dots, w_n\}$. Основной результат состоит в том, что существует тесная связь между структурой апостериорной сетки и сетки с относительной амплитудой весов $w_i \equiv \tilde{\mathcal{P}}(\Theta_i)\Delta\Theta_i$ для каждой точки $f_i \equiv f(\Theta_i)$. Регулировка разрешения сетки влияет на эти веса, при этом более равномерное распределение весов приводит к увеличению ESS, что может улучшить нашу оценку.

Тот факт, что уменьшение расстояния между точками (более плотная сетка) также уменьшает веса, имеет смысл: у нас больше точек, расположенных в этой области, поэтому каждая точка должна получить меньший относительный вес при вычислении $\mathbb{E}_{\mathcal{P}}[f(\Theta)]$. Аналогично, если у нас одинаковые расстояния между точками, но меняется относительная форма заднего плана, то вес этой точки при оценке $\mathbb{E}_{\mathcal{P}}[f(\Theta)]$ также должен измениться соответственно.

Теперь я хочу расширить это базовое соотношение. Теоретически, адаптивное увеличение разрешения нашей сетки позволяет нам лучше контролировать элементы объема $\Delta\Theta_i$, используемые для получения весов. Если мы достаточно хорошо знаем форму нашего постера, то для больших n мы теоретически должны быть в состоянии настроить $\Delta\Theta_i$ так, чтобы веса $w_i = \tilde{\mathcal{P}}(\Theta_i)\Delta\Theta_i$ были равномерными с некоторой желаемой точностью. По проверке, это должно произойти, когда

$$\Delta\Theta_i \propto \frac{1}{\tilde{\mathcal{P}}(\Theta_i)} \quad (30)$$

для всех i .

Если довести эти рассуждения до концептуального предела, то с ростом $n \rightarrow \infty$ мы можем представить, что оцениваем апостериор, используя все большее и большее количество точек сетки, расстояние между которыми $\Delta\Theta$ меняется как функция от Θ . Используя это, мы можем определить плотность точек $\mathcal{Q}(\Theta)$ на основе изменяющегося разрешения $\Delta\Theta(\Theta)$ нашей бесконечно тонкой сетки как функцию Θ :

$$\mathcal{Q}(\Theta) \propto \frac{1}{\Delta\Theta(\Theta)} \quad (31)$$

Этот результат говорит о том, что в континуальном пределе, где $n \rightarrow \infty$, структура нашей сетки с бесконечным разрешением эквивалентна новому непрерывному распределению $\mathcal{Q}(\Theta)$. Иллюстрация этой концепции показана на [Figure 6](#). Используя $\mathcal{Q}(\Theta)$, мы можем переписать наше исходное матожидание в виде

$$\mathbb{E}_{\mathcal{P}}[f(\Theta)] \equiv \frac{\int f(\Theta) \tilde{\mathcal{P}}(\Theta) d\Theta}{\int \tilde{\mathcal{P}}(\Theta) d\Theta} = \frac{\int f(\Theta) \frac{\tilde{\mathcal{P}}(\Theta)}{\mathcal{Q}(\Theta)} \mathcal{Q}(\Theta) d\Theta}{\int \frac{\tilde{\mathcal{P}}(\Theta)}{\mathcal{Q}(\Theta)} \mathcal{Q}(\Theta) d\Theta} = \frac{\mathbb{E}_{\mathcal{Q}}[f(\Theta) \tilde{\mathcal{P}}(\Theta)/\mathcal{Q}(\Theta)]}{\mathbb{E}_{\mathcal{Q}}[\tilde{\mathcal{P}}(\Theta)/\mathcal{Q}(\Theta)]} \quad (32)$$

По причинам, которые скоро станут понятны, я буду называть $\mathcal{Q}(\Theta)$ распределением предложений.

Сейчас это может показаться математическим трюком: все, что я сделал, это переписал наше исходное одно матожидание относительно (ненормированного) апостериорного $\tilde{\mathcal{P}}(\Theta)$ в терминах два матожидания относительно распределения предложения $\mathcal{Q}(\Theta)$. Эта замена, однако, на самом деле позволяет нам полностью реализовать связь между точками сетки и выборками.

Ранее я показал, что оценка матожидания для точек сетки в точности аналогична оценке, которую мы получили бы, если бы точки сетки были случайными выборками $\{f_1, \dots, f_n\}$ с соответствующими весами $\{w_1, \dots, w_n\}$. Однако после того, как мы определили наше ожидание относительно $\mathcal{Q}(\Theta)$, это утверждение может стать точным, если мы можем явно генерировать выборки из $\mathcal{Q}(\Theta)$.

Давайте быстро рассмотрим, что это значит. Изначально мы рассматривали попытку оценить $\mathbb{E}_{\mathcal{P}}[f(\Theta)]$ по сетке с n точками. Однако в пределе бесконечного разрешения наша сетка становится эквивалентной некоторому распределению $\mathcal{Q}(\Theta)$. Используя $\mathcal{Q}(\Theta)$, мы можем переписать наше исходное выражение в терминах двух ожиданий, $\mathbb{E}_{\mathcal{Q}}[f(\Theta) \tilde{\mathcal{P}}(\Theta)/\mathcal{Q}(\Theta)]$ и $\mathbb{E}_{\mathcal{Q}}[\tilde{\mathcal{P}}(\Theta)/\mathcal{Q}(\Theta)]$, над $\mathcal{Q}(\Theta)$ вместо $\mathcal{P}(\Theta)$. Это помогает нам, потому что теоретически мы можем оценить эти конечные выражения явно, используя серию из n случайно сгенерированных выборок из $\mathcal{Q}(\Theta)$. Из-за случайности, присущей этому подходу, его принято называть Монте-Карло подходом для оценки $\mathbb{E}_{\mathcal{P}}[f(\Theta)]$ из-за исторических связей со случайностью и азартными играми.

На первый взгляд, это удивительное утверждение. Когда мы вычисляем интеграл от функции $f(\Theta)$ на ограниченной сетке, мы знаем, что в нашем приближении есть некоторая ошибка, связанная с дискретизацией сетки. Эта ошибка полностью deterministic: учитывая количество точек сетки n и определенную плотность дискретизации $\mathcal{Q}(\Theta) \propto 1/\Delta\Theta(\Theta)$, мы каждый раз будем получать один и тот же результат (и ошибку) для $\mathbb{E}_{\mathcal{P}}[f(\Theta)]$.

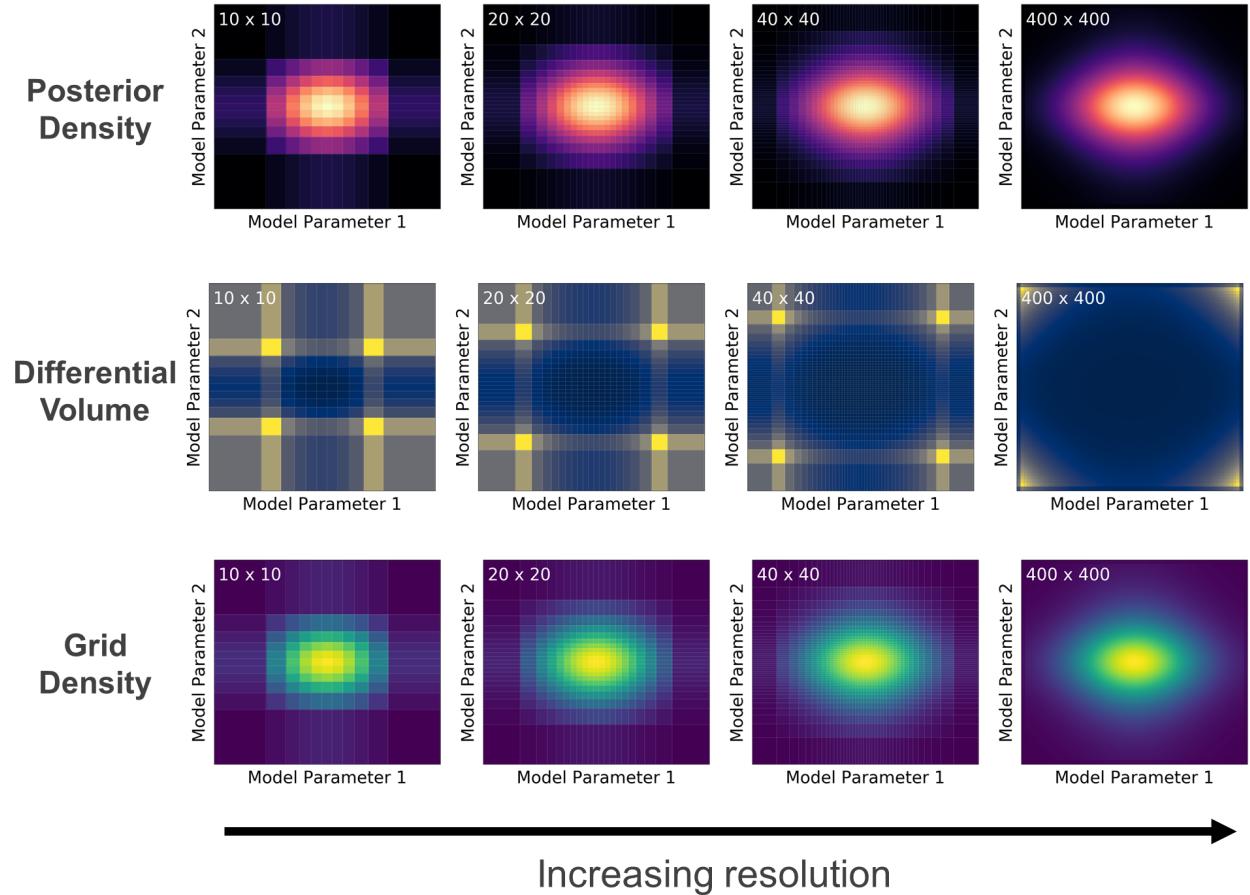


Рис. 6: Иллюстрация связи между сетками и непрерывными распределениями плотности. По мере увеличения числа точек сетки наша оценка апостериорного $\mathcal{P}(\Theta)$ улучшается (вверху). Поскольку расстояние между точками сетки меняется, чтобы максимизировать эффективный размер выборки (см. Figure 4 и §4.2), элементы дифференциального объема $\Delta\Theta_i$ меняются в зависимости от нашего местоположения (середина). При дальнейшем увеличении количества элементов объема плотность точек сетки в любом конкретном месте $\rho(\Theta_i) = [\Delta\Theta_i]^{-1}$ ведет себя как непрерывная функция $\mathcal{Q}(\Theta)$, распределение которой похоже на $\mathcal{P}(\Theta)$ (внизу). Это означает, что мы должны быть в состоянии использовать $\mathcal{Q}(\Theta)$ каким-то образом для оценки $\mathcal{P}(\Theta)$. Дополнительные подробности см. в §5.

В отличие от этого, построение n образцов $\{\Theta_1, \dots, \Theta_n\}$ из $\mathcal{Q}(\Theta)$ является по своей сути рандомным (т.е. стохастическим) процессом, который не похож на сетку точек. И поскольку эти точки по своей природе случайны, фактическое отклонение между нашей оценкой и истинным значением $\mathbb{E}_{\mathcal{P}}[f(\Theta)]$ будет тоже случайным. Таким образом, “ошибка” от случайных выборок говорит нам о том, насколько сильно может отличаться наша оценка от многих возможных реализаций нашего случайного процесса при определенном количестве выборок n , полученных из $\mathcal{Q}(\Theta)$. Тот факт, что мы можем получить примерно эквивалентные оценки на основе этих разных подходов при изменении n и $\mathcal{Q}(\Theta)$, лежит в основе связи между точками сетки и выборками.

Есть три основных преимущества перехода от аддитивно распределенной сетки к непрерывному распределению $\mathcal{Q}(\Theta)$. Во-первых, сетка всегда будет иметь некоторое минимальное разрешение $\Delta\Theta_i$, что затрудняет получение приблизительно равномерных весов, ограничивая максимальную ESS на практике. Напротив, теоретически мы можем добиться того, чтобы $\mathcal{Q}(\Theta)$ более точно соответствовал апостериору $\mathcal{P}(\Theta)$, что даст большую ESS при фиксированном n .

Во-вторых, поскольку мы теперь работаем с распределениями, а не с конечным числом точек сетки, мы больше не ограничены некоторым конечным объемом при оценке ожиданий. Поскольку распределения могут лежать в диапазоне $(-\infty, +\infty)$, мы можем гарантировать, что $\mathcal{Q}(\Theta)$ обеспечит достаточное покрытие по всем возможным значениям Θ , по которым может быть определено наше послесловие $\mathcal{P}(\Theta)$. Это означает, что некоторые теоретические вопросы, поднятые в §4.3, связанные с применением сеток к апостериорам, которые варьируются в диапазоне $(-\infty, +\infty)$, больше не применимы. Таким образом, методы Монте-Карло могут служить согласованными оценками для более широкого диапазона возможных апостериорных ожиданий, чем методы на основе сеток, что делает их существенно более гибкими.

Наконец, минимальное число точек сетки всегда экспоненциально растет с размерностью (см. §4.1), независимо от того, сколько параметров нас интересует для маргинализации. Поскольку методы Монте-Карло не полагаются на них, они могут в полной мере использовать преимущества маргинализации по параметрам при оценке ожиданий $\mathbb{E}_{\mathcal{P}}[f(\Theta)]$. Поэтому они менее подвержены этому эффекту (хотя см. §7.2).

5.2 Выборка по важности

Как я уже пытался подчеркнуть ранее, основной постулат этой статьи заключается в том, что мы не знаем, как выглядит $\mathcal{P}(\Theta)$ заранее. Это означает, что мы не знаем, какая структура сетки даст оптимальную оценку (т.е. максимум ESS) для $\mathbb{E}_{\mathcal{P}}[f(\Theta)]$, не говоря уже о том, как она должна вести себя в качестве $\mathcal{Q}(\Theta)$ в континуальном пределе. Это дает нам достаточную мотивацию для того, чтобы выбрать $\mathcal{Q}(\Theta)$ таким образом, чтобы сделать генерацию образцов из него простой и понятной.

Предположив, что мы выбрали такое $\mathcal{Q}(\Theta)$, мы можем впоследствии сгенерировать из него серию из n образцов. Предположим, что эти образцы имеют веса q_i , связанные с ними, и определим

$$f(\Theta_i) \equiv f_i, \quad \tilde{\mathcal{P}}(\Theta_i)/\mathcal{Q}(\Theta_i) \equiv \tilde{w}(\Theta_i) \equiv \tilde{w}_i \quad (33)$$

наше исходное выражение сводится к

$$\mathbb{E}_{\mathcal{P}} [f(\Theta)] = \frac{\mathbb{E}_{\mathcal{Q}} [f(\Theta)\tilde{w}(\Theta)]}{\mathbb{E}_{\mathcal{Q}} [\tilde{w}(\Theta)]} \approx \frac{\sum_{i=1}^n f_i \tilde{w}_i q_i}{\sum_{i=1}^n \tilde{w}_i q_i} \quad (34)$$

Если далее предположить, что мы выбрали $\mathcal{Q}(\Theta)$ так, что можем моделировать выборки, которые независимо и идентично распределены (iid) (т.е. каждая выборка имеет то же распределение вероятности, что и другие, и все выборки взаимно независимы), то соответствующие веса выборок немедленно сводятся к $q_i = 1/n$, и наш результат становится

$$\mathbb{E}_{\mathcal{P}} [f(\Theta)] \approx \frac{n^{-1} \sum_{i=1}^n f_i \tilde{w}_i}{n^{-1} \sum_{i=1}^n \tilde{w}_i} \quad (35)$$

Как и в предыдущем случае с сетками (§4), знаменатель этого выражения снова является прямым приближением для доказательства

$$\mathcal{Z} = \int \tilde{\mathcal{P}}(\Theta) d\Theta \approx n^{-1} \sum_{i=1}^n \tilde{w}_i \quad (36)$$

Это дает прямой "рецепт" для оценки нашего исходного значения матожидания:

1. Извлеките n iid образцов $\{\Theta_1, \dots, \Theta_n\}$ из $\mathcal{Q}(\Theta)$.
2. Вычислим их соответствующие веса $\tilde{w}_i = \tilde{\mathcal{P}}(\Theta_i)/\mathcal{Q}(\Theta_i)$.
3. Оценить $\mathbb{E}_{\mathcal{P}} [f(\Theta)]$. вычислив $\mathbb{E}_{\mathcal{Q}} [\tilde{w}(\Theta)]$ и $\mathbb{E}_{\mathcal{Q}} [f(\Theta)\tilde{w}(\Theta)]$ с использованием взвешенных выборочных средних.

Поскольку этот процесс заключается в "перевзвешивании" выборок на основе \tilde{w}_i , эти веса часто называют весами важности, а метод - Важной выборкой. Схематическая иллюстрация выборки по важности приведена на [Figure 7](#).

Мы можем интерпретировать веса важности как способ коррекции того, насколько "далека" наша первоначальная догадка $\mathcal{Q}(\Theta)$ от истины $\mathcal{P}(\Theta)$. Если в позиции Θ_i апостериорная плотность выше по сравнению с плотностью предложения, значит, мы с меньшей вероятностью сгенерировали выборку в этой позиции по сравнению с тем, что было бы, если бы мы брали выборки непосредственно из апостериорной. В результате мы должны увеличить соответствующий вес, чтобы учесть этот ожидаемый дефицит образцов в данной позиции. Если апостериорная плотность меньше плотности предложения, то верна альтернатива, и мы должны уменьшить вес соответствующего образца, чтобы учесть ожидаемый избыток образцов в данной позиции.

5.3 Примеры стратегий выборки

Выборка важности служит полезным первым шагом для понимания того, как веса $\{\tilde{w}_1, \dots, \tilde{w}_n\}$ для соответствующего набора образцов n связаны с различными стратегиями выборки Монте-Карло.

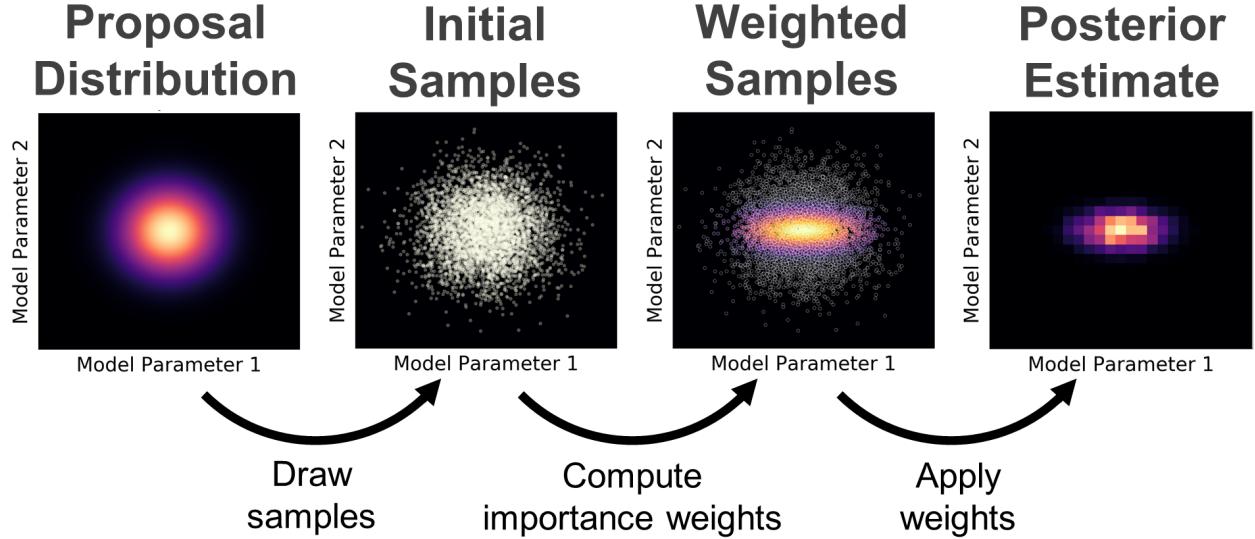


Рис. 7: Схематическая иллюстрация Importance Sampling. Сначала мы берем заданное распределение предложений $Q(\Theta)$ (слева) и генерируем из него набор из n иидных выборок (в середине слева). Затем мы взвешиваем каждый образец на основе соответствующей “важности” $\tilde{P}(\Theta)/Q(\Theta)$, которую он имеет в данном месте (середина справа). Затем мы можем использовать эти взвешенные выборки для аппроксимации апостериорных ожиданий (справа). Дополнительные сведения см. в §5.2.

Например, одним из распространенных подходов является равномерная генерация образцов в пределах некоторого кубоида с объемом V . Тогда распределение предложения будет иметь вид

$$Q^{\text{unif}}(\Theta) = \begin{cases} 1/V & \Theta \text{ in cuboid} \\ 0 & \text{otherwise} \end{cases} \quad (37)$$

Соответствующие веса важности впоследствии будут просто пропорциональны апостериору в данной позиции:

$$\tilde{w}_i^{\text{unif}} = \frac{\tilde{P}(\Theta_i)}{Q^{\text{unif}}(\Theta_i)} = V\tilde{P}(\Theta_i) \propto P(\Theta_i) \quad (38)$$

Другой возможный подход заключается в том, чтобы принять наше предложение за предварительное:

$$Q^{\text{prior}}(\Theta) = \pi(\Theta) \quad (39)$$

Это кажется вполне оправданным выбором: предшествующее значение характеризует наши знания до изучения данных, поэтому оно должно служить полезной первой догадкой и охватывать диапазон всех возможностей. При таком предположении мы находим, что наши веса будут равны вероятности $L(\Theta)$ для каждой позиции:

$$w_i^{\text{prior}} = \frac{\tilde{P}(\Theta_i)}{Q^{\text{prior}}(\Theta_i)} = \frac{L(\Theta_i)\pi(\Theta_i)}{\pi(\Theta_i)} = L(\Theta_i) \quad (40)$$

Наконец, обратите внимание, что оптимальная стратегия выборки заключается в предположении, что мы можем принять наше предложение идентичным нашему апостериору:

$$\mathcal{Q}^{\text{post}}(\Theta) = \mathcal{P}(\Theta) \quad (41)$$

Тогда соответствующие веса будут просто постоянными и равными доказательству \mathcal{Z} :

$$w_i^{\text{post}} = \frac{\tilde{\mathcal{P}}(\Theta_i)}{\mathcal{Q}^{\text{post}}(\Theta_i)} = \frac{\mathcal{Z}\mathcal{P}(\Theta_i)}{\mathcal{P}(\Theta_i)} = \mathcal{Z} \quad (42)$$

Как и ожидалось, этот результат гарантирует максимально возможную ESS, равную $n_{\text{eff}} = n$. Таким образом, получение $\mathcal{Q}(\Theta)$ как можно ближе к $\mathcal{P}(\Theta)$ становится важной частью анализа при попытке использовать Importance Sampling для оценки значений ожиданий. Именно этот результат, в частности, мотивирует использование методов Марковской цепи Монте-Карло (MCMC), обсуждаемых с §6 и далее: если мы можем каким-то образом генерировать выборки прямо из $\mathcal{P}(\Theta)$ или что-то близкое к нему, то мы можем достичь оптимальной оценки соответствующих значений ожиданий.

Exercise: Importance Sampling over a 2-D Gaussian

Setup

Let's return to our exercise from §4, in which our unnormalized posterior is well-approximated by a 2-D Gaussian (Normal) distribution:

$$\tilde{\mathcal{P}}(x, y) = \exp \left\{ -\frac{1}{2} \left[\frac{(x - \mu_x)^2}{\sigma_x^2} + \frac{(y - \mu_y)^2}{\sigma_y^2} \right] \right\}$$

where $(\mu_x, \mu_y) = (-0.3, 0.8)$ and $(\sigma_x^2, \sigma_y^2) = (2, 0.5)$.

Importance Sampling

We want to use Importance Sampling to approximate various posterior integrals from this distribution. We will start by choosing our proposal distribution $\mathcal{Q}(x, y)$ to be a 2-D Gaussian with a mean of 0 and standard deviation of 1:

$$\mathcal{Q}(x, y) = \mathcal{N}[(\mu_x, \mu_y) = (0, 0), (\sigma_x, \sigma_y) = (1, 1)]$$

Using $n = 25$ iid random samples drawn from the proposal distribution, compute an estimate for:

1. the evidence \mathcal{Z} ,
2. the means $\mathbb{E}_{\mathcal{P}}[x]$ and $\mathbb{E}_{\mathcal{P}}[y]$,
3. the 68% credible intervals (or closest approximation) $[x_{\text{low}}, x_{\text{high}}]$ and $[y_{\text{low}}, y_{\text{high}}]$,
4. and the effective sample size n_{eff} .

How accurate are each of these quantities with the values we might expect? What does n_{eff}/n tell us about how well our proposal $\mathcal{Q}(x, y)$ traces the underlying posterior $\mathcal{P}(x, y)$?

Uncertainty

Repeat the above exercise $m = 100$ times to get an estimate for how much our estimates of each quantity can vary. Is the variation in line with what might be expected given the typical effective sample size? Why or why not?

Convergence

Now repeat the above exercise using $n = 100$, $n = 1000$, and $n = 10000$ points rather than $n = 25$ points and comment on any differences. How much has the overall accuracy improved? Do the estimates appear convergent and consistent as n_{eff} increases? How much do the errors on quantities shrink as a function of n and/or n_{eff} ? Is this behavior expected? Why or why not?

Consistency

Next, let's expand our proposal distribution to instead have $(\sigma_x, \sigma_y) = (2, 2)$ to get more coverage in the "tails" of the posterior. Perform the same exercise as above with $n = \{100, 1000, 10000\}$ iid random samples. Do the answers change substantially? Why or why not?

While in theory we can choose $\mathcal{Q}(x, y) \approx \mathcal{P}(x, y)$ so that $n_{\text{eff}} \approx n$, we do not know the exact shape of the posterior ahead of time. Given that $\tilde{\mathcal{P}}(x, y)$ may differ from our initial expectations, what does this exercise imply about general concerns applying Importance Sampling in practice?

6 Markov Chain Monte Carlo

Now that we see how the weights relate to various Monte Carlo sampling strategies (e.g., generating samples from the prior), I will now outline the idea behind Markov Chain Monte Carlo (MCMC). In brief, MCMC methods try to generate samples in such a way that the importance weights $\{\tilde{w}_1, \dots, \tilde{w}_n\}$ associated with each sample are constant. Based on the results from §5.3, this means MCMC seeks to generate samples proportional to the posterior $\mathcal{P}(\Theta)$ in order to arrive at an optimal estimate for our expectation value.

MCMC accomplishes this by creating a chain of (correlated) parameter values $\{\Theta_1 \rightarrow \dots \rightarrow \Theta_n\}$ over n iterations such that the number of iterations $m(\Theta_i)$ spent in any particular region δ_{Θ_i} centered on Θ_i is proportional to the posterior density $\mathcal{P}(\Theta_i)$ contained within that region. In other words, the "density" of samples generated from MCMC

$$\rho(\Theta) \equiv \frac{m(\Theta)}{n} \tag{43}$$

at position Θ integrated over δ_{Θ} is approximately

$$\int_{\Theta \in \delta_{\Theta}} \mathcal{P}(\Theta) d\Theta \approx \int_{\Theta \in \delta_{\Theta}} \rho(\Theta) d\Theta \approx n^{-1} \sum_{j=1}^n \mathbf{1} [\Theta_j \in \delta_{\Theta}] \tag{44}$$

where $\mathbb{1}[\cdot]$ is the indicator function which evaluates to 1 if the inside condition is true and 0 otherwise. We can therefore approximate the density by simply adding up the number of samples within δ_{Θ} and normalizing by the total number of samples n . A schematic illustration of this concept is shown in [Figure 8](#).

While this will just be approximately true for any finite n , as the number of samples $n \rightarrow \infty$ this procedure generally guarantees that $\rho(\Theta) \rightarrow \mathcal{P}(\Theta)$ everywhere.² In theory then, once we have a reasonable enough approximation for $\rho(\Theta)$, we can also use the samples $\{\Theta_1 \rightarrow \dots \rightarrow \Theta_n\}$ generated from $\rho(\Theta)$ to get an estimate for the evidence using the same substitution trick introduced in §5:

$$\mathcal{Z} = \int \frac{\tilde{\mathcal{P}}(\Theta)}{\rho(\Theta)} \rho(\Theta) d\Theta \equiv \mathbb{E}_{\rho} \left[\tilde{\mathcal{P}}(\Theta)/\rho(\Theta) \right] \approx n^{-1} \sum_{i=1}^n \frac{\tilde{\mathcal{P}}(\Theta_i)}{\rho(\Theta_i)} \quad (45)$$

This is just the average of the ratio between $\tilde{\mathcal{P}}(\Theta_i)$ and $\rho(\Theta_i)$ over all n samples.

Finally, since our MCMC procedure gives us a series of n samples from the posterior, our expectation value simply reduces to

$$\mathbb{E}_{\mathcal{P}} [f(\Theta)] \approx \frac{n^{-1} \sum_{i=1}^n f_i \tilde{w}_i}{n^{-1} \sum_{i=1}^n \tilde{w}_i} = \frac{n^{-1} \sum_{i=1}^n f_i}{n^{-1} \sum_{i=1}^n 1} = n^{-1} \sum_{i=1}^n f_i \quad (46)$$

This is just the sample mean of the corresponding $\{f_1, \dots, f_n\}$ values over our set of n samples.

I wish to take a moment here to highlight two features of the above results related to common misconceptions surrounding MCMC methods. First, there is a widespread belief that because MCMC methods generate a chain of samples whose behavior follows the posterior, we do not have any ability to use them to estimate normalizing constants such as the evidence \mathcal{Z} . As shown above, this is not true at all: not only can we do this using $\rho(\Theta)$, but the estimate we derive is actually a consistent one (although it will converge slowly; see §7.1).

The second misconception is that the primary goal of MCMC is to “approximate” or “explore” the posterior. In other words, to estimate $\rho(\Theta)$. However, as shown above, the ability of MCMC methods to estimate $\rho(\Theta)$ is really only useful for estimating the evidence \mathcal{Z} . In fact, by tracing its heritage from Importance Sampling-based methods, we see its primary purpose is actually to estimate expectation values (i.e. integrals over the posterior). I have explicitly tried to avoid introducing any mention of “approximating the posterior” up to this point in order to avoid this misconception, but will spend some time discussing this point in more detail in §7.1.

To summarize, the idea behind MCMC is to simulate a series of values $\{\Theta_1 \rightarrow \dots \rightarrow \Theta_n\}$ in a way that their density $\rho(\Theta)$ after a given amount of time follows the underlying posterior $\mathcal{P}(\Theta)$. We can then estimate the posterior within any particular region δ_{Θ} by simply counting up how many samples we simulate there and normalizing by the total number of samples n we generated. Because we are also simulating values directly from the posterior, any expectation values also reduce to simple sample averages. This procedure is incredibly intuitive and part of the reason MCMC methods have become so widely adopted.

²Discussing the details of exactly when/where this condition holds in theory and in practice is beyond the scope of this paper but can be found in other references such as Asmussen & Glynn (2011) and Brooks et al. (2011).

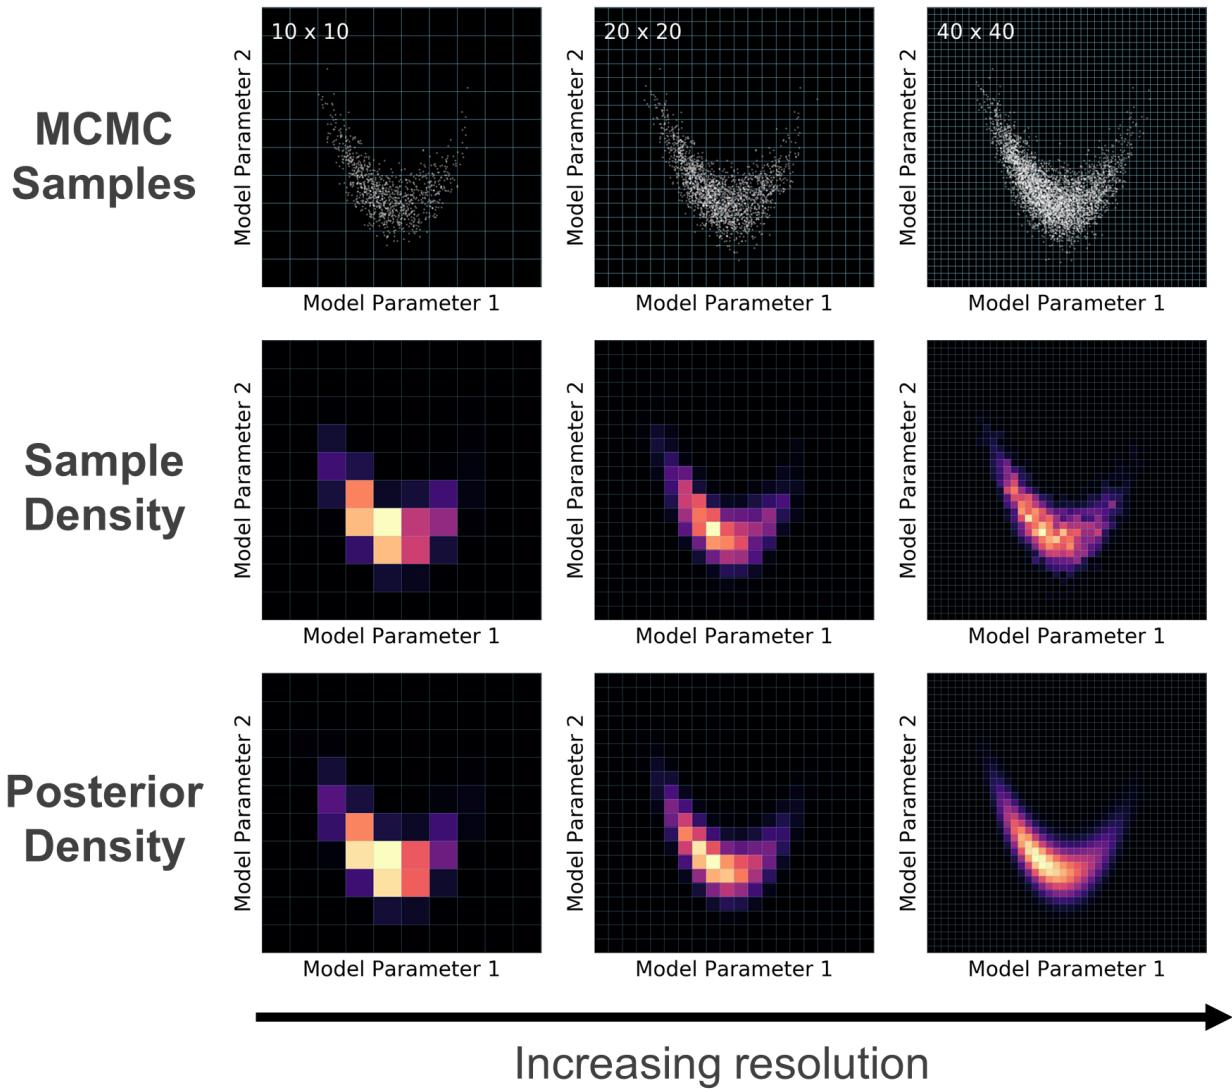


Fig. 8: A schematic illustration of Markov Chain Monte Carlo (MCMC). MCMC tries to create a chain of n (correlated) samples $\{\Theta_1 \rightarrow \dots \rightarrow \Theta_n\}$ (top) such that the number of samples m in some particular volume δ gives a relative density m/n (middle) comparable to the posterior $\mathcal{P}(\Theta)$ integrated over the same volume (bottom). See §6 for additional details.

6.1 Generating Samples with the Metropolis-Hastings Algorithm

There is a vast literature on various approaches to generating samples (see, e.g., [cites](#)). Since this article focuses on building up a conceptual understanding of MCMC methods, exploring how the majority of these methods behave both in theory and in practice is beyond the scope of this paper.

Instead of an overview, I aim to clarify the basics of how these methods operate. The central idea is that we want a way to generate new samples $\Theta_i \rightarrow \Theta_{i+1}$ such that the distribution of the final samples $\rho(\Theta)$ as $n \rightarrow \infty$ (1) is stationary (i.e. it converges to something) and (2) is equal to the $\mathcal{P}(\Theta)$. These are essentially analogs to the convergence and consistency constraints discussed in §4.3.

We can satisfy the first condition by invoking detailed balance. This is the idea that probability is conserved when moving from one position to another (i.e. the process is reversible). More formally, this just reduces to factoring of probability:

$$P(\Theta_{i+1}|\Theta_i)P(\Theta_i) = P(\Theta_{i+1}, \Theta_i) = P(\Theta_i|\Theta_{i+1})P(\Theta_{i+1}) \quad (47)$$

where $P(\Theta_{i+1}|\Theta_i)$ is the probability of moving from $\Theta_i \rightarrow \Theta_{i+1}$ and $P(\Theta_i|\Theta_{i+1})$ is the probability of the reverse move from $\Theta_{i+1} \rightarrow \Theta_i$. Rearranging then gives the following constraint:

$$\frac{P(\Theta_{i+1}|\Theta_i)}{P(\Theta_i|\Theta_{i+1})} = \frac{P(\Theta_{i+1})}{P(\Theta_i)} = \frac{\mathcal{P}(\Theta_{i+1})}{\mathcal{P}(\Theta_i)} \quad (48)$$

where the final equality comes from the fact that the distribution we are trying to generate samples from is the posterior $\mathcal{P}(\Theta)$.

We now need to implement a procedure that enables us to actually move to new positions by computing this probability. We can do this by breaking each move into two steps. First, we want to propose a new position $\Theta_i \rightarrow \Theta'_{i+1}$ based on a proposal distribution $\mathcal{Q}(\Theta'_{i+1}|\Theta_i)$ similar in nature to the $\mathcal{Q}(\Theta)$ used in Importance Sampling (§5.2). Then we will either decide to accept the new position ($\Theta_{i+1} = \Theta'_{i+1}$) or reject the new position ($\Theta_{i+1} = \Theta_i$) with some transition probability $T(\Theta'_{i+1}|\Theta_i)$. Combining these terms together then gives us the probability of moving to a new position:

$$P(\Theta_{i+1}|\Theta_i) \equiv \mathcal{Q}(\Theta_{i+1}|\Theta_i)T(\Theta_{i+1}|\Theta_i) \quad (49)$$

As with Importance Sampling, we can choose $\mathcal{Q}(\Theta'_{i+1}|\Theta_i)$ so that it is straightforward to propose new samples Θ'_{i+1} by numerical simulation. We then need to determine the transition probability $T(\Theta'_{i+1}|\Theta_i)$ of whether we should accept or reject Θ'_{i+1} . Substituting into our expression for detailed balance, we find that our form for the transition probability must satisfy the following constraint:

$$\frac{T(\Theta_{i+1}|\Theta_i)}{T(\Theta_i|\Theta_{i+1})} = \frac{\mathcal{P}(\Theta_{i+1})}{\mathcal{P}(\Theta_i)} \frac{\mathcal{Q}(\Theta_i|\Theta_{i+1})}{\mathcal{Q}(\Theta_{i+1}|\Theta_i)} \quad (50)$$

It is straightforward to show that the Metropolis criterion [Metropolis et al. \(1953\)](#)

$$T(\Theta_{i+1}|\Theta_i) \equiv \min \left[1, \frac{\mathcal{P}(\Theta_{i+1})}{\mathcal{P}(\Theta_i)} \frac{\mathcal{Q}(\Theta_i|\Theta_{i+1})}{\mathcal{Q}(\Theta_{i+1}|\Theta_i)} \right] \quad (51)$$

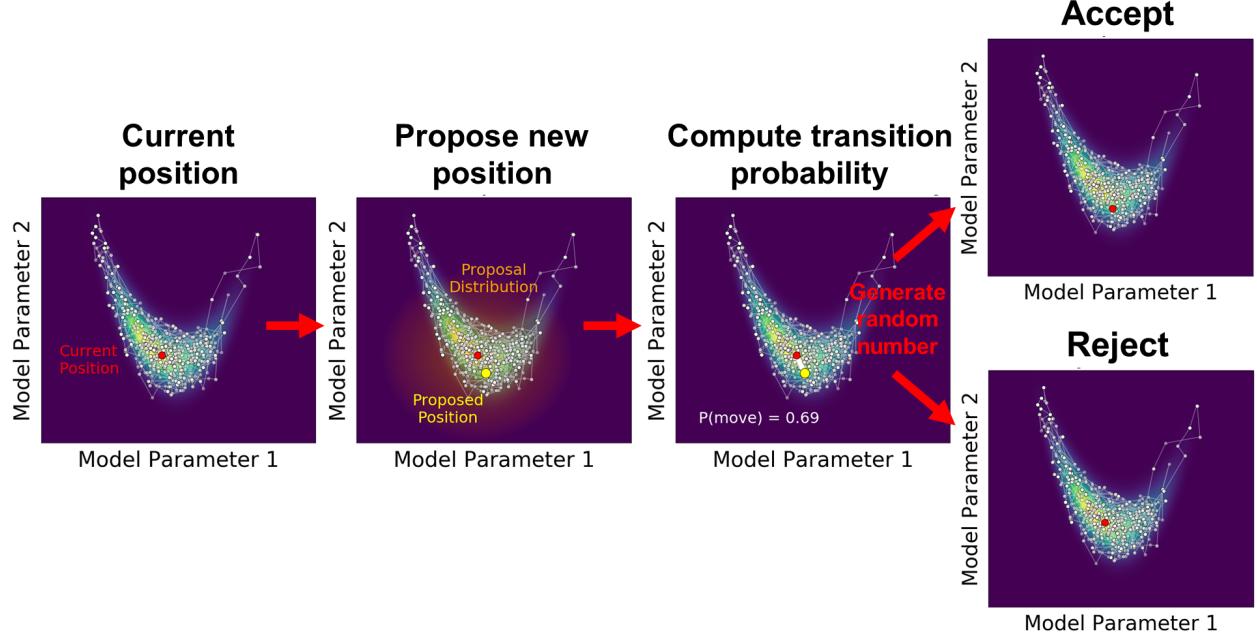


Fig. 9: A schematic illustration of the Metropolis-Hastings algorithm. At a given iteration i , we have generated a chain of samples $\{\Theta_1 \rightarrow \dots \rightarrow \Theta_i\}$ (white) up to the current position Θ_i (red) whose behavior follows the underlying posterior $\mathcal{P}(\Theta)$ (viridis color map). We then propose a new position Θ'_{i+1} (yellow) from the proposal distribution (orange shaded region). We then compute the transition probability $T(\Theta'_{i+1}|\Theta_i)$ (white) based on the posterior $\mathcal{Q}(\Theta)$ and proposal $\mathcal{Q}(\Theta'|\Theta)$ densities. We then generate a random number u_{i+1} uniformly from 0 to 1. If $u_{i+1} \leq T(\Theta'_{i+1}|\Theta_i)$, we accept the move and make our next position in the chain $\Theta_{i+1} = \Theta'_{i+1}$. If we reject the move, then $\Theta_{i+1} = \Theta_i$. See §6.1 for additional details.

satisfies this constraint.

Generating samples following this approach can be done using the Metropolis-Hastings (MH) Algorithm (Metropolis et al., 1953; Hastings, 1970):

1. Propose a new position $\Theta_i \rightarrow \Theta'_{i+1}$ by generating a sample from the proposal distribution $\mathcal{Q}(\Theta'_{i+1}|\Theta_i)$.
2. Compute the transition probability $T(\Theta'_{i+1}|\Theta_i) = \min \left[1, \frac{\mathcal{P}(\Theta'_{i+1})}{\mathcal{P}(\Theta_i)} \frac{\mathcal{Q}(\Theta_i|\Theta'_{i+1})}{\mathcal{Q}(\Theta'_{i+1}|\Theta_i)} \right]$.
3. Generate a random number u_{i+1} from $[0, 1]$.
4. If $u_{i+1} \leq T(\Theta'_{i+1}|\Theta_i)$, accept the move and set $\Theta_{i+1} = \Theta'_{i+1}$. If $u_{i+1} > T(\Theta'_{i+1}|\Theta_i)$, reject the move and set $\Theta_{i+1} = \Theta_i$.
5. Increment $i = i + 1$ and repeat this process.

See Figure 9 for a schematic illustration of this process.

Because algorithms like the MH algorithm generate a chain of states where the next proposed position only depends on the current position rather than any of its past positions

(i.e. it “forgets” the past), they are known as Markov processes. Combining these two terms with the Monte Carlo nature of simulating new positions is what gives Markov Chain Monte Carlo (MCMC) its namesake.

An issue with generating a chain of samples in practice is the fact that our chain only has finite length and a starting position Θ_0 . If our chain were infinitely long, we would expect it to visit every possible position in parameter space, rendering the exact starting position unimportant. However, since in practice we terminate sampling after only n iterations, starting from a location Θ_0 that has an extremely low probability means an inordinate fraction of our n samples will occupy this low-probability region, possibly biasing our final results. Since we have limited knowledge beforehand about where Θ_0 is relative to our posterior, in practice we generally want to remove the initial chain of states once we are confident our chain has begun sampling from higher-probability regions. Discussing various approaches for identifying and removing samples from this burn-in period is beyond the scope of this article; for additional information, please see Gelman & Rubin (1992), Gelman et al. (2013), and Vehtari et al. (2019) along with references therein.

6.2 Effective Sample Size and Auto-Correlation Time

At this point, MCMC seems like it should be the optimal method for any situation: by simulating samples directly from the (unknown) posterior, we can achieve an optimal estimate for any expectation values we wish to evaluate. In practice, however, this does not hold true. MCMC values rely on specific algorithmic procedures such as the MH algorithm to generate samples, whose limiting behavior reduces to a chain of samples $\{\Theta_1 \rightarrow \dots \rightarrow \Theta_n\}$ whose distribution follows the posterior. Any given sample Θ_i , however, is more likely than not to be correlated with both the previous sample in the sequence Θ_{i-1} and the subsequent sample in the sequence Θ_{i+1} .

This occurs for two reasons. First, new positions Θ_i drawn from $\mathcal{Q}(\Theta_i | \Theta_{i-1})$ by construction tend to depend on the current position Θ_{i-1} . This means that the position we propose at iteration $i + 1$ from will be correlated with the position at iteration i , which itself will be correlated with the position at iteration $i - 1$, etc.

Second, even if we set $\mathcal{Q}(\Theta' | \Theta) = \mathcal{Q}(\Theta')$ so that all of our proposed positions are uncorrelated, our transition probability $T(\Theta' | \Theta)$ still ensures that we will eventually reject the new position so that $\Theta_{i+1} = \Theta_i$. Since samples at exactly the same position are maximally correlated, this ensures that samples from our chain will “on average” have non-zero correlations. Note that having low acceptance fractions (i.e. the fraction of proposals that are accepted rather than rejected) will lead to a larger fraction of the chain containing these perfectly correlated samples, increasing the overall correlation.

As mentioned in §4.2, correlated samples provide less information about the underlying distribution they are sampled from since their behavior doesn’t just depend on the underlying distribution but also the neighboring samples in the sequence. Samples that are more highly correlated then should lead to a reduced ESS.

This intuition can be quantified by introducing the auto-covariance $C(t)$ for some integer lag t . Assuming that we have an infinitely long chain $\{\Theta_1 \rightarrow \dots\}$, the auto-covariance $C(t)$

is:

$$C(t) \equiv \mathbb{E}_i [(\Theta_i - \bar{\Theta}) \cdot (\Theta_{i+t} - \bar{\Theta})] = \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n (\Theta_i - \bar{\Theta}) \cdot (\Theta_{i+t} - \bar{\Theta}) \quad (52)$$

where \cdot is the dot product. In other words, we want to know the covariance between Θ_i at some iteration i and Θ_{i+t} at some other iteration $i + t$, averaged over all possible pairs of samples (Θ_i, Θ_{i+t}) in our infinitely long chain. Note that the amplitude $|C(t)|$ will be maximized at $|C(t=0)|$, where the two samples being compared are identical, and minimized with $|C(t)| = 0$ when Θ_i and Θ_{i+t} are completely independent from each other.

Using the auto-covariance, we can define the corresponding auto-correlation $A(t)$ as

$$A(t) \equiv \frac{C(t)}{C(0)} \quad (53)$$

This now measures the average degree of correlation between samples separated by an integer lag t . In the case where $t = 0$, both samples are identical and $A(t=0) = 1$. In the case where the samples are uncorrelated over lag t , $A(t) = 0$.

The overall auto-correlation time for our chain is just the auto-correlation $A(t)$ summed over all non-zero lags ($t \neq 0$):

$$\tau \equiv \sum_{t=-\infty}^{\infty} A(t) - 1 = 2 \sum_{t=1}^{\infty} A(t) \quad (54)$$

where the -1 comes from the fact that the auto-correlation with no lag is just $A(t=0) = 1$ (i.e. each sample perfectly correlates with itself) and the substitution arises from the fact that $A(t) = A(-t)$ by symmetry. If $\tau = 0$, then it takes no time at all for samples to become uncorrelated and the samples can be assumed to be iid. If $\tau > 0$, then it takes on average τ additional iterations for samples to become uncorrelated. An illustration of this process is shown in [Figure 10](#).

Incorporating the auto-correlation time leads directly to a modified definition for the ESS:

$$n'_{\text{eff}} \equiv \frac{n_{\text{eff}}}{1 + \tau} \quad (55)$$

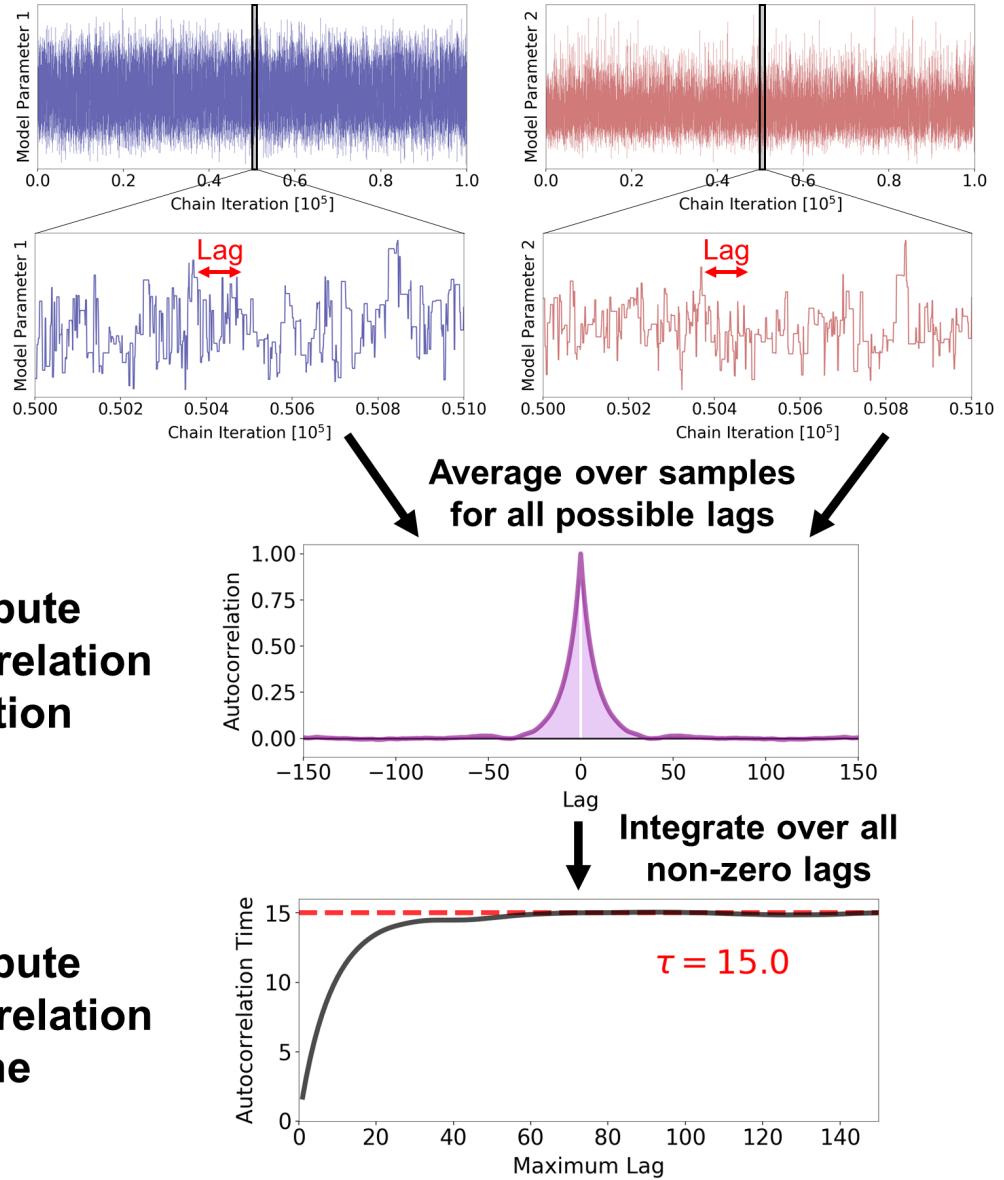
In practice, we cannot precisely compute τ since we do not have an infinite number of samples and do not know $\mathcal{P}(\Theta)$. Therefore we often need to generate an estimate $\hat{\tau}$ of the auto-correlation time using the existing set of n samples we have. While discussing various approaches taken to derive $\hat{\tau}$ is beyond the scope of this work, please see Brooks et al. (2011) for additional details.

The fact that MCMC methods are subject to non-negative auto-correlation times ($\tau \geq 0$) but have optimal importance weights $\tilde{w}_i = 1$ give an ESS of

$$n'_{\text{eff,MCMC}} = \frac{n_{\text{eff,MCMC}}}{1 + \tau} = \frac{n}{1 + \tau} \leq n \quad (56)$$

This means that there is no guarantee that MCMC is always the optimal choice to achieve the largest ESS. In particular, Importance Sampling methods, which can generate fully iid

**Generate
chain of
samples**



**Compute
auto-correlation
function**

**Compute
auto-correlation
time**

Рис. 10: A schematic illustration of the auto-correlation associated with MCMC. MCMC methods generate a chain of samples $\{\Theta_1 \rightarrow \dots \rightarrow \Theta_n\}$ (top), but these tend to be strongly correlated on small length scales (top middle). We can quantify the degree of correlation by computing the corresponding auto-correlation $A(t)$ over our set of samples and all possible time lags t (bottom middle). This quantity is 1 when $t = 0$ and drops to 0 as $t \rightarrow \pm\infty$. The overall auto-correlation time τ associated with our chain of samples is then just the integrated auto-correlation over $t \neq 0$. See §6.2 for additional details.

samples with no auto-correlation time ($\tau = 0$) but non-optimal importance weights \tilde{w}_i , instead have an ESS of

$$n'_{\text{eff,IS}} = \frac{n_{\text{eff,IS}}}{1 + \tau} = n_{\text{eff,IS}} = \frac{\left(\sum_{i=1}^n \tilde{w}_i\right)^2}{\sum_{i=1}^n \tilde{w}_i^2} \leq n \quad (57)$$

which can be greater than $n'_{\text{eff,MCMC}}$ at fixed n .

Given the results above, it should now be clear that the central motivating concern of MCMC methods is whether they can generate a chain of samples with an auto-correlation time small enough to outperform Importance Sampling. Whether or not this is true will depend on the posterior, the approach used to generate the chain of samples (see §6.1 and §8) and the proposal distribution $\mathcal{Q}(\Theta)$ used for Importance Sampling (see §5.3).

Exercise: MCMC over a 2-D Gaussian

Setup

Let's again return to our examples from §4 and §5, in which our unnormalized posterior is well-approximated by a 2-D Gaussian (Normal) distribution:

$$\tilde{\mathcal{P}}(x, y) = \exp \left\{ -\frac{1}{2} \left[\frac{(x - \mu_x)^2}{\sigma_x^2} + \frac{(y - \mu_y)^2}{\sigma_y^2} \right] \right\}$$

where $(\mu_x, \mu_y) = (-0.3, 0.8)$ and $(\sigma_x^2, \sigma_y^2) = (2, 0.5)$.

We want to use MCMC to approximate various posterior integrals from this distribution. We will start by choosing our proposal distribution $\mathcal{Q}(x', y' | x, y)$ to be a 2-D Gaussian with a mean of 0 and standard deviation of 1:

$$\mathcal{Q}(x', y' | x, y) = \mathcal{N}[(\mu_x, \mu_y) = (x, y), (\sigma_x, \sigma_y) = (1, 1)]$$

Parameter Estimation

Using the above proposal, generate $n = 1000$ samples following the MH algorithm starting from the position $(x_0, y_0) = (0, 0)$. Using these samples, compute an estimate of the means $\mathbb{E}_{\mathcal{P}}[x]$ and $\mathbb{E}_{\mathcal{P}}[y]$ as well as the corresponding 68% credible intervals (or closest approximation) $[x_{\text{low}}, x_{\text{high}}]$ and $[y_{\text{low}}, y_{\text{high}}]$. How accurate are each of these quantities compared with the values we might expect?

Evidence Estimation

Next, use a set of 10×10 bins from $x = [-5, 5]$ and $y = [-5, 5]$ to construct an estimate $\rho(x, y)$ from the resulting set of samples. Using this estimate for the density, compute an estimate of the evidence \mathcal{Z} . How accurate is our approximation? Does it substantially change if we adjust the number and/or size of the bins?

Auto-Correlation Time and Effective Sample Size

Use numerical methods to compute an estimate of the auto-correlation time τ and the corresponding effective sample size n_{eff} . How efficient is our sampling (n_{eff}/n) compared to the default Importance Sampling approach from the exercise in §5? Does this mirror what we'd expect given the acceptance fraction of our proposals? What do these quantities tell us about how well our proposal $\mathcal{Q}(x, y)$ matches the structure of the underlying posterior $\mathcal{P}(x, y)$?

Uncertainties

Repeat the above exercises $m = 30$ times to get an estimate for how much our estimates of each quantity can vary. Is the variation in line with what might be expected given the typical effective sample size?

Consistency and Convergence

Now repeat the above exercise using $n = 2500$ and $n = 10000$ samples points and comment on any differences. How much has the overall accuracy improved? Do the estimates appear convergent and consistent as n_{eff} increases? How much do the errors on quantities shrink as a function of n and/or n_{eff} ? Is this similar or different from the observed dependence from the Importance Sampling exercise in §5?

Sampling Efficiency

Next, adjust the (σ_x, σ_y) of the proposal distribution to try and improve n_{eff} at fixed n . How close is the final ratio σ_x/σ_y of our proposal to that of the underlying posterior? Are there any additional scaling differences between the rough size of our proposal $\mathcal{Q}(x', y'|x, y)$ relative to the underlying posterior $\mathcal{P}(x, y)$? Given that $\tilde{\mathcal{P}}(x, y)$ may differ from the structure assumed when picking $\mathcal{Q}(x', y'|x, y)$, can you think of any possible scheme to try and adjust our proposal using an existing set of samples?

Burn-In

Finally, adjust the starting position to be at $(x_0, y_0) = (10, 10)$ instead of $(0, 0)$ and generate a new chain of samples. Plot the x and y positions of the chain over time. Are there any obvious signs of the burn-in period? How many samples roughly should be assigned to burn-in and subsequently removed from our chain? Are there any possible heuristics that might help to identify the initial burn-in period?

7 Sampling the Posterior with MCMC

The approach by which MCMC methods are able to generate a chain of samples immediately gives a mental image of our chain “exploring” the posterior. While it is true that the density of samples from the chain $\rho(\Theta) \rightarrow \mathcal{P}(\Theta)$ as $n \rightarrow \infty$, the primary purpose of MCMC is estimating expectation values $\mathbb{E}_{\mathcal{P}}[f(\Theta)]$. Although this might seem like a subtle difference,

this distinction is actually crucial for understanding how MCMC algorithms (should) behave in practice. We discuss this in more detail below.

7.1 Approximating the Posterior

Although algorithms such as MH (§6.1) are constructed to ensure the density of the chain of samples $\rho(\Theta)$ generated by MCMC converges to the posterior $\mathcal{P}(\Theta)$ as $n \rightarrow \infty$, this does not necessarily translate into an efficient method to approximate the posterior in practice. In other words, n might need to be extremely large for this constraint to hold. So how many samples do we need to ensure $\rho(\Theta)$ is a good approximation to $\mathcal{P}(\Theta)$?

To start, we first need to define some metric for what a “good” approximation is. A reasonable one might be that we would like to know the posterior within some region δ_Θ to within some precision ϵ so that

$$\left| \frac{1}{n} \sum_{i=1}^n \mathbf{1}[\Theta_i \in \delta_\Theta] - \int_{\delta_\Theta} \mathcal{P}(\Theta) d\Theta \right| \equiv |\hat{p}(\delta_\Theta) - p(\delta_\Theta)| < \epsilon \quad (58)$$

where $p(\delta_\Theta)$ is the total probability contained within δ_Θ and $\hat{p}(\delta_\Theta)$ is the fraction of the MCMC chain of samples contained within the same region. While it might seem strange to only estimate this for one region, I will shortly generalize this to encompass the entire³ posterior.

In the ideal case where our samples are iid and drawn from $\mathcal{P}(\Theta)$, our samples each have a probability $p(\delta_\Theta)$ of being within δ_Θ . The probability that $\hat{p}(\delta_\Theta) = m/n$ then follows the binomial distribution:

$$P\left(\hat{p}(\delta_\Theta) = \frac{m}{n}\right) = \binom{n}{m} [p(\delta_\Theta)]^m [1 - p(\delta_\Theta)]^{n-m} \quad (59)$$

In other words, our samples end up inside δ_Θ a total of m times with probability $p(\delta_\Theta)$ and outside δ_Θ a total of $n - m$ times with probability $1 - p(\delta_\Theta)$. The additional binomial coefficient $\binom{n}{m}$ for “ n choose m ” accounts for all possible unique cases where m samples can end up within δ_Θ out of our total sample size of n .

This distribution has a mean of $p(\delta_\Theta)$, so for any finite n we expect $\hat{p}(\delta_\Theta)$ to be an unbiased estimator of $p(\delta_\Theta)$:

$$\mathbb{E}[\hat{p}(\delta_\Theta) - p(\delta_\Theta)] = p(\delta_\Theta) - p(\delta_\Theta) = 0 \quad (60)$$

The variance, however, depends on the sample size:

$$\mathbb{E}[|\hat{p}(\delta_\Theta) - p(\delta_\Theta)|^2] = \frac{p(\delta_\Theta)[1 - p(\delta_\Theta)]}{n} \quad (61)$$

In practice, we can expect there to be some non-zero auto-correlation time $\tau > 0$. This will increase the number of MCMC samples we will need to generate to be confident that our

³Technically the procedure outlined in this section only works for finite volumes. The basic intuition, however, holds even when parameters are unbounded although proving those results is beyond the scope of this work.

estimate $\hat{p}(\delta_{\Theta})$ is well-behaved. Inserting a factor of $1 + \tau$ and substituting our expectation value from above into our accuracy constraint then gives a rough constraint for the number of samples n we would require as a function of ϵ :

$$n \gtrsim \frac{p(\delta_{\Theta}) [1 - p(\delta_{\Theta})]}{\epsilon^2 / (1 + \tau)} \sim \frac{\hat{p}(\delta_{\Theta}) [1 - \hat{p}(\delta_{\Theta})]}{\epsilon^2} \times (1 + \hat{\tau}) \quad (62)$$

The final substitution of $p(\delta_{\Theta})$ and τ with their noisy estimates $\hat{p}(\delta_{\Theta})$ and $\hat{\tau}$ arises from the fact that in practice we don't know $p(\delta_{\Theta})$ or τ (both of which require full knowledge of the posterior). We are therefore forced to rely on estimators derived from our set of n samples.

Let's now examine this result more closely. As expected, the total number of samples is proportional to $1 + \hat{\tau}$: if it takes longer to generate independent samples, then we need more samples to be confident we have characterized the posterior well in a given region. We also see that $n \propto \epsilon^{-2}$, so that if we want to reduce the error by a factor of x we need to increase our sample size by a factor of x^2 .

The behavior in the numerator is more interesting. Note that $\hat{p}(\delta_{\Theta}) [1 - \hat{p}(\delta_{\Theta})]$ is maximized for $\hat{p}(\delta_{\Theta}) = 0.5$, and so the largest sample size needed is when we have split our posterior directly in half. In all other cases the sample size needed will be smaller because there will be more samples outside or inside the region of interest whose information we can leverage. The exact value of $\hat{p}(\delta_{\Theta})$ of course depends on both the posterior $\mathcal{P}(\Theta)$ and the target region δ_{Θ} : the sample size needed to approximate the posterior to some ϵ near the peak of the distribution (the small region where $\mathcal{P}(\Theta)$ is large) will likely be different than the sample size needed to accurately estimate the tails of the distribution (the large region where $\mathcal{P}(\Theta)$ is small).

While the above argument holds if we are looking to estimate the posterior in just one region, "converging to the posterior" implies that we want $\rho(\Theta)$ to become a good approximation to $\mathcal{P}(\Theta)$ everywhere. We can enforce this new requirement by splitting our posterior into m different sub-regions $\{\delta_{\Theta_1}, \dots, \delta_{\Theta_m}\}$ and requiring that each sub-region is well constrained:

$$|\hat{p}(\delta_{\Theta_1}) - p(\delta_{\Theta_1})| < \epsilon_1 \quad \dots \quad |\hat{p}(\delta_{\Theta_m}) - p(\delta_{\Theta_m})| < \epsilon_m \quad (63)$$

Substituting in the expected errors on each of these constraints then gives us an approximate limit on the number of samples n_j that we need to estimate the posterior in each region δ_{Θ_j} :

$$n_j \gtrsim \frac{\hat{p}(\delta_{\Theta_j}) [1 - \hat{p}(\delta_{\Theta_j})]}{\epsilon_j^2} \times (1 + \hat{\tau}) \quad (64)$$

The total number of samples we need is then simply:

$$n \gtrsim \sum_{j=1}^m n_j \quad (65)$$

This approach of dividing up our posterior into sub-regions is conceptually similar to the grid-based approaches described in §4. As such, it is also subject to the same drawbacks: we expect the number of regions m to increase exponentially with the number of dimensions

d . For instance, if we just wanted to divide our posterior up into m orthants we would end up with $m = 2^d$ regions: 2 in 1-D (left-right), 4 in 2-D (upper-left, lower-left, upper-right, lower-right), 8 in 3-D, etc.

This effect implies that we should in general expect the number of samples required to ensure $\rho(\Theta)$ is a good approximation to $\mathcal{P}(\Theta)$ for some specified accuracy ϵ to scale as

$$n \gtrsim k^d \quad (66)$$

where k is a constant that depends on the accuracy requirements. This puts approximating the full posterior firmly in the “curse of dimensionality” regime (see §4.1).⁴

While many practitioners talk about MCMC being an efficient method to “approximate the posterior”, in practice it is rarely used to approximate $\mathcal{P}(\Theta)$ directly. As discussed in §3 and shown in [Figure 2](#), almost all quantities that are reported in the literature do not rely on approximations to the full d -dimensional posterior, but rather approximations to marginalized distributions that are almost always restricted to no more than $k \lesssim 3$ parameters at a time. The act of marginalizing over the remaining $d - k$ parameters helps to counteract the curse of dimensionality illustrated here. While it is technically fair to say that MCMC can “explore” the marginalized k -D posteriors for certain limited sets of parameters, this type of language can often lead to more misconceptions than insights.

7.2 Posterior Volume

The basic consequences outlined in §7.1 are more general than the specific case where we imagine dividing up the posterior into orthants or other regions. Fundamentally, computing any expectation over the posterior $\mathbb{E}_{\mathcal{P}}[f(\Theta)]$ requires integrating over the entire domain of our parameters Θ . We therefore want to understand how the volume of this domain behaves (i.e. how many parameter combinations there are). Once we have a grasp on how this behaves, we can then start trying to quantify how this will impact our estimates.

To start, let’s consider the d -dimensional hyper-cube (the d -cube) with side length ℓ in all d dimensions. Its volume scales as

$$V(\ell) = \prod_{i=1}^d \ell = \ell^d \quad (67)$$

The differential volume element between ℓ and $\ell + d\ell$ is

$$dV(\ell) = (d \times \ell^{d-1}) \times (d\ell) \propto \ell^{d-1} \quad (68)$$

This exponential scaling with dimensionality means that volume becomes increasingly concentrated in thin shells located in regions located progressively further away from the center of the d -cube. As an example, consider the length-scale

$$\ell_{50} = 2^{-1/d}\ell \quad (69)$$

⁴A direct corollary of this result is that, while the evidence estimates from MCMC are consistent, the rate of convergence to the underlying value will proceed exponentially more slowly as d increases.

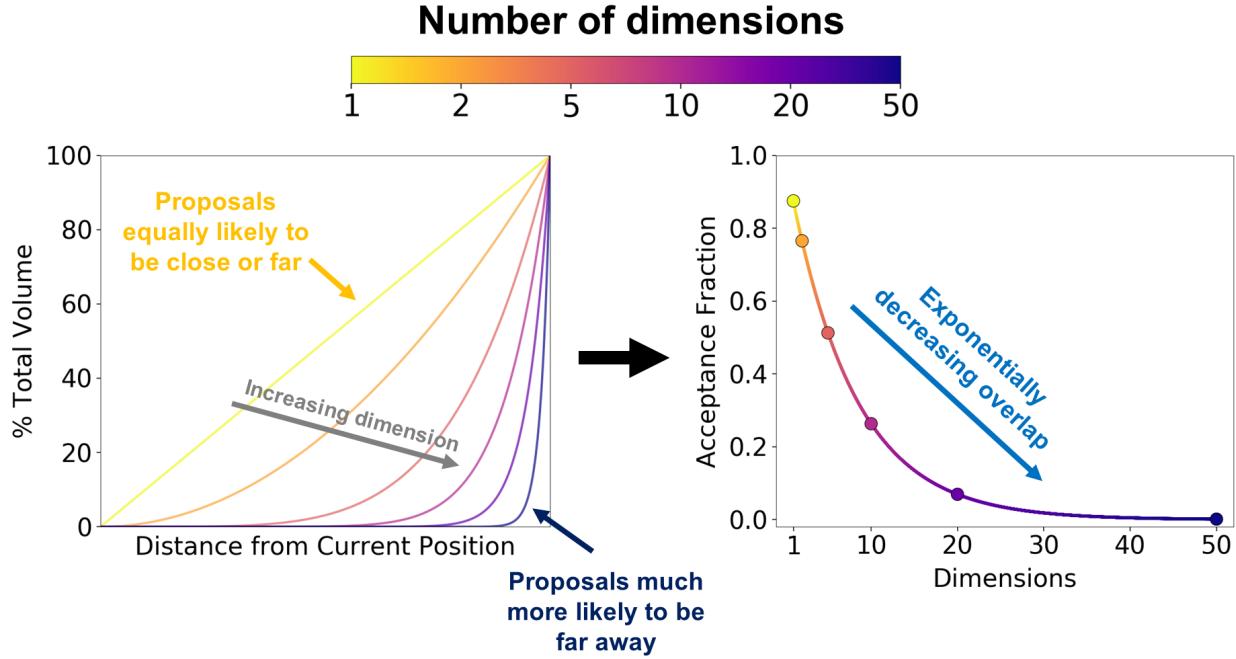


Рис. 11: A schematic illustration of how the curse of dimensionality affects MCMC acceptance fractions via posterior volume. At a given position Θ , the volume increases $\propto r^d$ as a function of distance r away from that position (left). As the dimensionality increases, this implies volume becomes concentrated progressively further out, leading to larger distances between proposed positions Θ' and the current position Θ . Most of these positions have significantly lower posterior probabilities $\mathcal{P}(\Theta')$ compared to the current value $\mathcal{P}(\Theta)$, leading to an exponential decline in the typical acceptance fraction (and a corresponding increase in the auto-correlation time) as the dimensionality increases (right). Adjusting the size and/or shape of the proposal $\mathcal{Q}(\Theta'|\Theta)$ can help to counteract this behavior. See §7.2 for additional details.

that divides the d -cube into two equal-sized regions with 50% of the volume contained interior to ℓ_{50} and 50% of the volume exterior to ℓ_{50} . In 1-D, this gives $\ell_{50}/\ell = 0.5$ as we'd expect. In 2-D, this gives $\ell_{50}/\ell \approx 0.7$. In 3-D, $\ell_{50}/\ell \approx 0.8$. In 7-D, $\ell_{50}/\ell \approx 0.9$. By the time we get to 15-D, we have $\ell_{50}/\ell \approx 0.95$, which means that 50% of the volume is located in the last 5% of the length-scale near the boundary of the d -cube. While the constants may change when considering other shapes (e.g., spheres), in general this exponential scaling as a function of d is a generic feature of higher-dimensional volumes. In other words, increasing the number of parameters leads to an exponential increase in the number of available parameter combinations that we have to explore.

In addition to affecting the long-term behavior of MCMC, this exponential increase in volume also directly impacts how MCMC methods operate. To see why this is the case, we need look no further than the transition probability used in the MH algorithm discussed in

§6.1:

$$T(\Theta_{i+1}|\Theta_i) \equiv \min \left[1, \frac{\mathcal{P}(\Theta_{i+1})}{\mathcal{P}(\Theta_i)} \frac{\mathcal{Q}(\Theta_i|\Theta_{i+1})}{\mathcal{Q}(\Theta_{i+1}|\Theta_i)} \right]$$

The non-trivial portion of this expression cleanly splits into two terms. The first is dependent on the volume and is related to how we proposed our next position from $\mathcal{Q}(\Theta'|\Theta)$. The second is dependent on the density and is related to how the posterior density changes between the two positions.

In practice, our transition probability can be interpreted as a basic corrective approach: after proposing a new position from some nearby volume, we then try to “correct” for differences between our proposal and the underlying posterior by only accepting these moves sometimes based on changes in the underlying density. In high dimensions, this basic “tug of war” between the volume (proposal) and the density (posterior) can break down as the vast majority of an object’s volume becomes concentrated near the outer edges.⁵ For instance, in the case where our proposal $\mathcal{Q}(\Theta'|\Theta)$ is a cube with side-length ℓ centered on Θ , this leads to a median length-scale of $\ell_{50} = 2^{-1/d}\ell$, which increases rapidly from 0.5ℓ to $\approx \ell$ as the dimensionality increases. The same logic also applies to other proposal distributions (see §8). This focus on positions either far away or with very similar separation length-scales as $\ell_{50} \rightarrow \ell$ means that many choices of $\mathcal{Q}(\Theta'|\Theta)$ have a tendency to “overshoot”, proposing new positions with much smaller posterior densities compared to the current position. These new positions are then almost always rejected, leading to extremely low acceptance fractions and correspondingly long auto-correlation times. An example of this effect is illustrated in Figure 11.

One of the main ways to counteract this behavior is to adjust the size/shape of the proposal $\mathcal{Q}(\Theta'|\Theta)$ so that the fraction of proposed positions that are accepted remains sufficiently high. This helps to ensure the posterior density $\mathcal{P}(\Theta)$ does not change too drastically when proposing positions new positions, leading to lower overall auto-correlation times. Details of how to implement these schemes in practice are beyond the scope of this article; please see citation for additional details.

7.3 Posterior Mass and Typical Sets

Above, I described how the behavior of volume in high dimensions can impact the performance of our MCMC MH sampling algorithm, possibly leading to inefficient proposals and low acceptance fractions. Let’s assume that we have resolved this problem and have an efficient way of generating our chain of samples. We now have a secondary question: where are these samples located?

From our discussion in §7.1, we know that the highest density of samples $\rho(\Theta)$ will be located where the posterior density $\mathcal{P}(\Theta)$ is also correspondingly high. However, this region δ_Θ might only correspond to a small portion of the posterior. Indeed, given there is exponentially more volume as the dimensionality increases, it is almost guaranteed that models with many parameters Θ will have the vast majority of the posterior located outside the region of highest density.

⁵Alternative methods such as Hamiltonian Monte Carlo (Neal, 2012) can get around this problem by smoothly incorporating changes in the density and volume.

A consequence of this is that the majority of samples in our chain will be located away from the peak density. As a result, our chain spends the majority of its time generating samples in these regions. This has a huge impact in the way our chain is expected to behave: while the highest concentration of samples will be located in the regions of highest posterior density, the largest amount of samples will actually be located in the regions of highest posterior mass (i.e. density times volume). Since this implies that a “typical” sample (picked at random) will most likely be located in this region of high posterior mass, this region is also commonly referred to as the typical set.

To make this argument a little easier to conceptualize, let’s imagine that we have a 3-parameter model $\Theta = (x, y, z)$ and $\mathcal{P}(x, y, z)$ is spherically symmetric. While we could imagine trying to integrate over $\mathcal{P}(x, y, z)$ directly in terms of $dxdydz$, it is almost always easier to instead integrate over such a distribution in “shells” with differential volume $dV(r) = 4\pi r^2 dr$ as a function of radius $r = \sqrt{x^2 + y^2 + z^2}$. This allows us to rewrite the 3-D integral over (x, y, z) as a 1-D integral over r :

$$\int \mathcal{P}(x, y, z) dxdydz = \int \mathcal{P}(r) 4\pi r^2 dr \equiv \int \mathcal{P}'(r) dr \quad (70)$$

where $\mathcal{P}'(r) \equiv 4\pi r^2 \mathcal{P}(r)$ is now the 1-D density as a function of r . This “boosts” the contribution as a function of r by the differential volume element of the shell associated with $\mathcal{P}(r)$, and implies that the the posterior should have some sort of shell-like structure (i.e. $\mathcal{P}'(r)$ is maximized for $r > 0$).

Although not all posterior densities can be expected to be spherically-symmetric in this way, in general we can rewrite the d -D integral over Θ as a 1-D volume integral over V defined by some unknown iso-posterior contours⁶

$$\int \mathcal{P}(\Theta) d\Theta = \int \mathcal{P}(V) dV \quad (71)$$

As outlined in §7.2, we generically expect the size of each volume element to go as $dV \sim r^{d-1} dr$ where r is the distance from the peak of posterior. So the basic intuition we get from the simple spherically-symmetric case still applies and we expect

$$\int \mathcal{P}(V) dV \sim \int \mathcal{P}(r) r^{d-1} dr = \int \mathcal{P}'(r) dr \quad (72)$$

As before, the differential volume element of the shell associated with $\mathcal{P}(r)$ “boosts” its overall contribution as a function of r . This boost also becomes exponentially stronger as d increase. For even moderately-sized d , we therefore expect the posterior mass to be mostly contained in a thin shell located at a radius r' with some width $\Delta r'$. See [Figure 12](#) for an illustration of this effect based on the toy problem presented in §8.1.

This result has two immediate implications. First, the majority of our samples are not located where the posterior density is maximized. This is the result of an exponentially increasing number of parameter combinations, which allow a small handful of excellent fits to the data to be easily overwhelmed by a substantially larger number of mediocre fits.

⁶Indeed, alternative Monte Carlo methods such as Nested Sampling (Skilling, 2004, 2006) or Bridge/Path Sampling (Gelman & Meng, 1998) actually are designed to evaluate this type of volume integral explicitly.

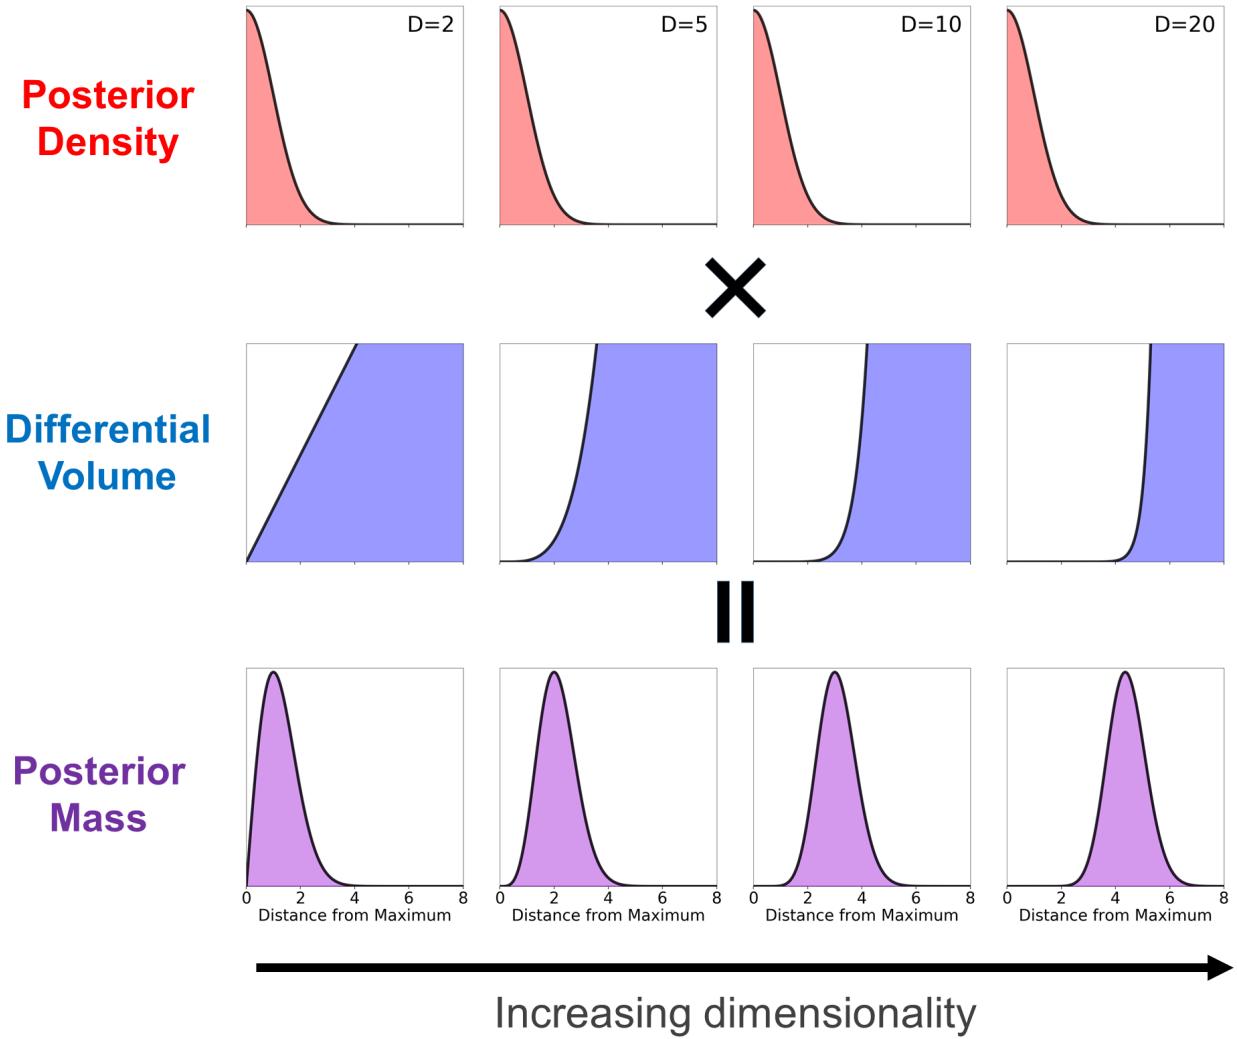


Рис. 12: A schematic illustration of how the posterior mass behaves as a function of dimensionality using a d -dimensional Gaussian. The top panel shows the posterior density $\mathcal{P}(r) \propto e^{-r^2/2}$ (red) plotted as a function of distance r from the maximum posterior density at $r = 0$ as the number of dimensions d increases (left to right). As expected, this distribution remains constant. The middle panel shows the differential volume element $dV(r) \propto r^{d-1}dr$ (blue) of the corresponding shell at radius r . This illustrates the exponentially increasing volume contributed by shells further away from the maximum. The bottom panel shows corresponding “posterior mass” as a function of radius $\mathcal{P}'(r) \propto r^{d-1}\mathcal{P}(r) \propto r^{d-1}e^{-r^2/2}$ (purple). Due to the increasing amount of volume located further away from the maximum posterior density, we see that the majority of the posterior mass (and therefore of any samples we generate with MCMC) are actually located a shell located far away from the $r = 0$. See §7.3 for additional details.

MCMC methods are therefore generally inefficient at locating and/or characterizing the region of peak posterior density.

Second, as d increases we generally would expect the radius of the shell containing the bulk of the posterior mass to increase, moving further and further away from the peak density due to the exponentially increasing available volume. Since the majority of our samples are located in this region, our chain will spend the vast majority of time generating samples from this shell.

This allows us to now outline exactly why it is challenging to propose samples efficiently in high dimensions:

1. To make sure our acceptance fractions remain reasonable, we need to ensure our proposed positions mostly lie within this shell of posterior mass.
2. However, obtaining an independent sample requires being able to (in theory) propose any position within this shell.
3. This means that our auto-correlation time will principally be set by how long it takes to “wander around” the shell, which will be a function of its overall size r' , its width $\Delta r'$, and the number of dimensions d .

8 Application to a Simple Toy Problem

I now consider a concrete, detailed example to illustrate how all the concepts discussed in §6 and §7 come together in practice. Throughout this section, I will outline a number of analytic results and utilize several different MCMC sampling strategies to generate chains of samples. I strongly encourage interested readers to implement their own versions of the methods outlined here, which can be used to reproduce the numerical results from this section in their entirety.

8.1 Toy Problem

In this toy problem, we will take our (unnormalized) posterior to be a d -dimensional Gaussian (Normal) distribution with a mean of $\mu = 0$ and a standard deviation of σ in all dimensions:

$$\tilde{\mathcal{P}}(\Theta) = \exp\left[-\frac{1}{2} \frac{|\Theta|^2}{\sigma^2}\right] \quad (73)$$

where $|\Theta|^2 = \sum_{i=1}^d \Theta_i^2$ is the squared magnitude of the position vector.

Based on the results from §7.3, we can better understand the properties of this distribution by rewriting the posterior density in terms of the “radius” $r \equiv |\Theta| = \sqrt{\sum_{i=1}^d \Theta_i^2}$ away from the center:

$$\tilde{\mathcal{P}}(r) = \exp\left[-\frac{r^2}{2\sigma^2}\right] \quad (74)$$

The corresponding volume contained within a given radius r is then

$$V(r) \propto r^d \quad (75)$$

The corresponding posterior mass is $\tilde{\mathcal{P}}'(r)$ is then defined via

$$\tilde{\mathcal{P}}(V)dV(r) \propto e^{-r^2/2\sigma^2} r^{d-1} dr \equiv \tilde{\mathcal{P}}'(r)dr$$

Note that this is closely related to the chi-square distribution.

The typical radius r_{peak} where the posterior mass peaks (i.e. is maximized) and a sample is most likely to be located can be derived by setting $d\tilde{\mathcal{P}}'(r)/dr = 0$. Solving this gives

$$r_{\text{peak}} = \sqrt{d-1}\sigma \quad (76)$$

In other words, while in 1-D a typical sample is most likely to be located at the peak of the distribution with $r_{\text{peak}} = 0$, in higher dimensions this changes quite drastically. While $r_{\text{peak}} = 1\sigma$ in 2-D, it is 2σ in 5-D, 3σ in 10-D, and 5σ in 26-D. This is a direct consequence of the huge amount of volume at larger radii in high dimensions: although a sample at $r = 5\sigma$ has a posterior density $\mathcal{P}(r)$ orders of magnitude worse than a sample at $r = 0$, the enormous number of parameter combinations (volume) available at $r = 5\sigma$ more than makes up for it.

In general, we expect the posterior mass to comprise a “Gaussian shell” centered at some radius

$$r_{\text{mean}} \equiv \mathbb{E}_{\mathcal{P}'}[r] = \int_0^\infty r \mathcal{P}'(r) dr = \sqrt{2} \frac{\Gamma(\frac{d+1}{2})}{\Gamma(\frac{d}{2})} \sigma \approx \sqrt{d}\sigma \quad (77)$$

with a standard deviation of

$$\Delta r_{\text{mean}} \equiv \sqrt{\mathbb{E}_{\mathcal{P}'}[(r - r_{\text{mean}})^2]} = \sigma \sqrt{d - 2 \left(\frac{\Gamma(\frac{d+1}{2})}{\Gamma(\frac{d}{2})} \right)^2} \approx \frac{\sigma}{\sqrt{2}} \quad (78)$$

where $\Gamma(d)$ is the Gamma function and the approximations are taken for large d . See [Figure 12](#) for an illustration of this behavior.

8.2 MCMC with Gaussian Proposals

Let us now consider a chain of samples $\{\Theta_1 \rightarrow \dots \rightarrow \Theta_n\}$. The distance between two samples Θ_m and Θ_{m+t} separated by some lag t will be

$$|\Theta - \Theta'| = \sqrt{\sum_{i=1}^d (\Theta_{m,i} - \Theta_{m+t,i})^2} \quad (79)$$

Assuming that the lag $t \gg \tau$ is substantially larger than the auto-correlation time τ , we can assume each sample is approximately iid distributed following our Gaussian posterior. This then gives an expected separation of

$$\Delta r_{\text{sep}} \equiv \sqrt{\mathbb{E}_{\mathcal{P}}[|\Theta_m - \Theta_{m+t}|^2]} = \sqrt{\sum_{i=1}^d \mathbb{E}_{\mathcal{P}}[(\Theta_{m,i} - \Theta_{m+t,i})^2]} = \sqrt{2d}\sigma \approx \sqrt{2}r_{\text{mean}} \quad (80)$$

We can in theory propose samples in such a way so that the separation $|\Theta_{i+1} - \Theta_i|$ between a proposed position Θ_{i+1} and the current position Θ_i follows the ideal separation of $\sqrt{2}r_{\text{mean}}$ derived above by using a simple Gaussian proposal distribution:

$$\mathcal{Q}(\Theta_{i+1} | \Theta_i) \propto \exp \left[-\frac{1}{2} \frac{|\Theta_{i+1} - \Theta_i|^2}{2\sigma^2} \right] \quad (81)$$

While this proposal has the same shape as the posterior, it is centered on Θ_i rather than 0. Using our intuition for how volume behaves based on §7.2, we can conclude that the majority of samples proposed from this choice of $\mathcal{Q}(\Theta' | \Theta)$ will probably have little overlap with the posterior.

Indeed, numerical simulation suggests the typical fraction of positions that will be accepted given the above proposal roughly scales as

$$\langle f_{\text{acc}}(d) \rangle \equiv \exp [\mathbb{E}_{\mathcal{P}, \mathcal{Q}} [\ln T(\Theta_{i+1} | \Theta_i)]] \sim \exp \left[-\frac{d}{4} - \frac{1}{2} \right] \quad (82)$$

which decreases exponentially as the dimensionality increases, similar to Figure 11. Likewise, we find the auto-correlation time roughly scales as

$$\langle \tau(d) \rangle \equiv \exp [\mathbb{E}_{\mathcal{P}, \mathcal{Q}} [\ln \tau]] \sim \exp \left[\frac{d}{4} + \frac{7}{4} \right] \quad (83)$$

This exponential dependence arises because the overlap between the typical Gaussian proposal $\mathcal{Q}(\Theta' | \Theta)$ and the underlying posterior $\mathcal{P}(\Theta)$ essentially reduces to the small volume where two thin shells overlap. Since the radii of the shells goes as $\propto \sqrt{d}$ while the widths remain roughly constant, the “fractional size” of the shell (and the corresponding overlap) ends up decreasing exponentially.

To counteract this effect, we need to adjust the σ of our proposal distribution by some factor γ :

$$\mathcal{Q}_\gamma(\Theta_{i+1} | \Theta_i) \propto \exp \left[-\frac{1}{2} \frac{|\Theta_{i+1} - \Theta_i|^2}{(\gamma\sigma)^2} \right] \quad (84)$$

where our previous proposal assumes $\gamma = \sqrt{2}$. If we want to ensure our typical acceptance fraction will remain roughly constant as a function of dimension d , γ needs to scale as

$$\langle f_{\text{acc}}(\gamma(d)) \rangle \approx C \Rightarrow \gamma(d) \propto \frac{1}{\sqrt{d}} \quad (85)$$

which inversely tracks the expected radius r_{mean} of the typical set. We find that taking

$$\gamma = \frac{\delta}{\sqrt{d}} \quad (86)$$

leads to a typical acceptance fraction of

$$\langle f_{\text{acc}}(\delta/\sqrt{d}) \rangle \approx \exp \left[-\left(\frac{\delta^2}{4} \right)^2 - \frac{\delta}{2} \right] \quad (87)$$

as d becomes large with a typical auto-correlation time of

$$\langle \tau(\delta/\sqrt{d}) \rangle \approx 3d \quad (88)$$

for reasonable choices of δ . This linear dependence is a substantial improvement over our earlier exponential scaling.

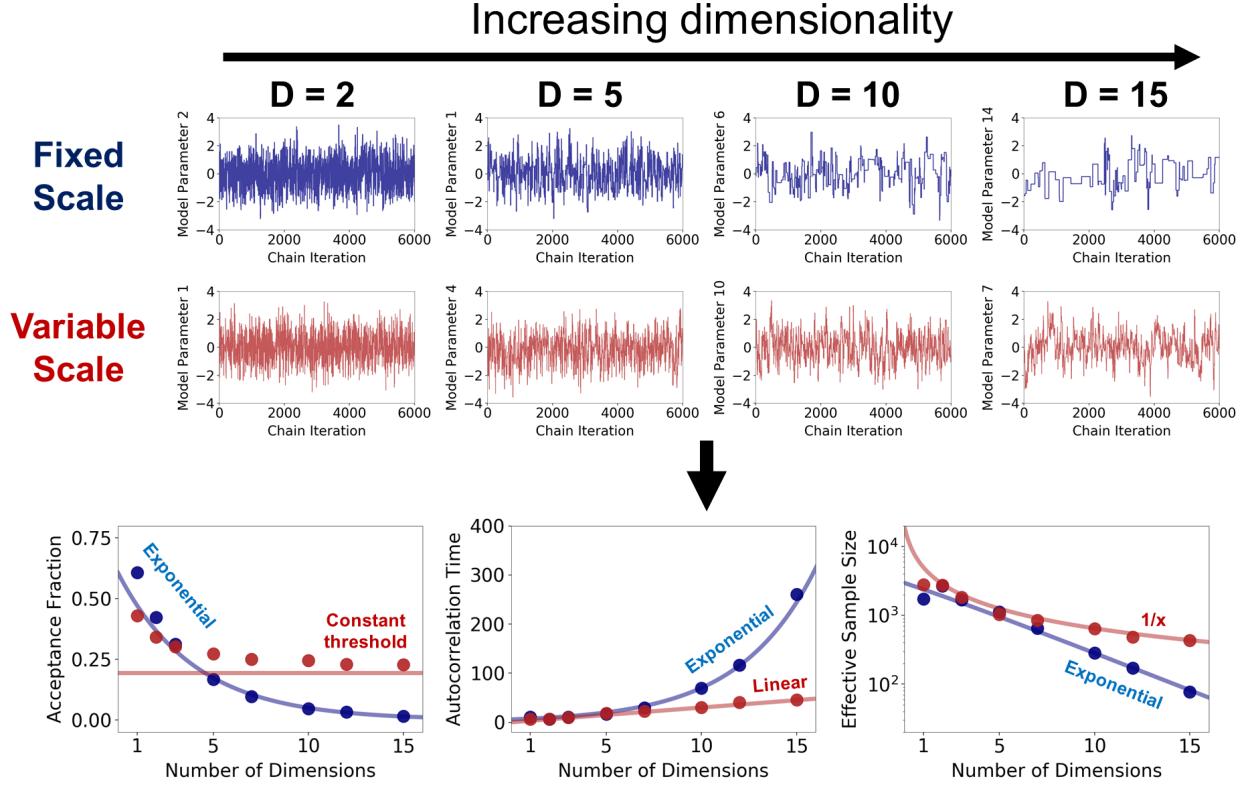


Fig. 13: Numerical results showcasing the performance of a simple MH MCMC sampler with Gaussian proposals on our toy problem, a d -dimensional Gaussian with mean $\mu = 0$ and standard deviation $\sigma = 1$ in every dimension. The top series of panels show snapshots of a random parameter from the chain as a function of dimensionality (increasing from left to right) assuming an unchanging proposal with constant scale factor $\gamma = \sqrt{2}$ (blue) and a shrinking proposal with $\gamma = 2.5/\sqrt{d}$ designed to target a constant acceptance fraction of $\sim 25\%$ (red). The bottom panels show the corresponding acceptance fractions (left), auto-correlation times (middle), and effective sample sizes (right) from our chains (colored points) as a function of dimensionality. The approximations from §8.2 are shown as light colored lines. Shrinking the size of the proposal helps to keep samples within the bulk of the posterior mass, substantially reducing the auto-correlation time and increasing the effective sample size. Failing to do so leads to an exponentially decreasing fraction of good proposals and a corresponding exponential increase/decrease in the auto-correlation time/effective sample size. See §8.2 for additional discussion.

Numerical Tests

To confirm these results, I sample from this d -dimensional Gaussian posterior (assuming $\sigma = 1$ for simplicity) using two MH MCMC algorithms for $n = 20,000$ iterations based on these proposal distributions. The first proposes new points assuming $\gamma = \sqrt{2}$. The second assumes $\gamma = 2.5/\sqrt{d}$ in order to maintain a roughly constant acceptance fraction of 25%. As shown in [Figure 13](#), the chains behave as expected given our theoretical predictions as a function of dimensionality, with the constant proposal quickly becoming stuck while the adaptive proposal continues sampling normally. While the auto-correlation time τ increases in both cases, the increase in the latter case (where it is driven by decreasing size/scale of the proposal distribution) is much more manageable than the former (where it is driven by the exponentially decreasing acceptance fraction).

8.3 MCMC with Ensemble Proposals

One drawback to the Gaussian proposals explored above is that we have to specify the structure of the distribution ahead of time. In this specific case, we assumed that:

1. the width of the posterior in each dimension (parameter) was constant such that $\sigma_1 = \sigma_2 = \dots = \sigma_n = \sigma$ and
2. the parameters were entirely uncorrelated with each other such that the correlation coefficient $\rho_{ij} = 0$ between any two dimensions i and j .

In general, there is no good reason to assume that either of these are true. This means we have to also estimate the entire set of $d(d + 1)/2$ free parameters that determine the overall covariance structure of our unknown posterior distribution. Trying to adjust the covariance structure in order to improve our sampling efficiency and decrease the auto-correlation time (see §5.3 and §6.2) becomes one of the most difficult parts of running MCMC algorithms in practice.

While there are schemes to perform these adjustments during an extended burn-in period (see, e.g., [Brooks et al. 2011](#)), there is significant appeal in methods that can “auto-tune” without much additional input from the user. One class of such approaches are known as ensemble or particle methods. These methods attempt to use many m chains running simultaneously (i.e. in parallel) to improve the performance of any individual chain.

We explore three variations of ensemble methods here that attempt to exploit $m \gtrsim d(d + 1)/2$ chains running simultaneously:

1. using the ensemble of particles to condition a Gaussian proposal distribution,
2. using trajectories from multiple particles along with Gaussian “jitter”, and
3. using affine-invariant transformations of trajectories from multiple particles.

A schematic illustration of these methods is shown in [Figure 14](#).

As we might expect, an immediate drawback of these methods is they rely on having enough particles to characterize the overall structure of the space (i.e. the curse of dimensionality). While this limits their utility when sampling from high-dimensional spaces, they can be

attractive options in moderate-dimensional spaces ($d \lesssim 25$) where a few hundred particles are often sufficient to ensure reasonable performance.

8.3.1 Gaussian Proposal

The first approach is simply a modified Gaussian proposal: at any iteration i for any chain j , we propose a new position Θ_{i+1}^j based on the current position Θ_i^j using a Gaussian proposal

$$\mathcal{Q}_\gamma^j(\Theta_{i+1}^j | \Theta_i^j) \propto \exp \left[-\frac{1}{2} (\Theta_{i+1}^j - \Theta_i^j)^T (\gamma^2 \mathbf{C}_i^j)^{-1} (\Theta_{i+1}^j - \Theta_i^j) \right] \quad (89)$$

where T is the transpose operator and

$$\mathbf{C}_i^j = \text{Cov} [\{\Theta_i^1, \dots, \Theta_i^{j-1}, \Theta_i^{j+1}, \dots, \Theta_i^m\}] \quad (90)$$

is the empirical covariance matrix estimated from the current positions of the m chains excluding chain j . We repeat this process for each of the m chains in turn.

In other words, at each iteration i we want to update all m chains. We do so by updating each chain j in turn based on what the other chains are currently doing. Assuming the current position of each chain is distributed following the underlying posterior $\mathcal{P}(\Theta)$, it is straightforward to show that \mathbf{C}_i^j is a reasonable approximation to the unknown covariance structure of our posterior. In addition, because we exclude j when computing \mathbf{C}_i^j , this proposal is symmetric going from $\Theta_i^j \rightarrow \Theta_{i+1}^j$ and from $\Theta_{i+1}^j \rightarrow \Theta_i^j$. This means that we satisfy detailed balance and do not have to incorporate any proposal-dependent factors when computing the transition probability.

8.3.2 Ensemble Trajectories with a Gaussian Proposal

The approach taken in §8.3.1 solves the problem of trying to tune the covariance of our initial Gaussian proposal. However, it still assumes that a Gaussian proposal is the optimal solution. A more general approach is one that does not rely on assuming a proposal explicitly, but rather only relies on the distribution of the remaining particles.

One such approach used in the literature is Differential Evolution MCMC (DE-MCMC; Storn & Price, 1997; Ter Braak, 2006). The main idea behind DE-MCMC is to rely on the relative positions of the chains at a given iteration i when making new proposals. We first randomly select two other particles k and l where $\Theta_i^j \neq \Theta_i^k \neq \Theta_i^l$. We then propose a new position based on the vector distance between the other two particles $\Theta_i^k - \Theta_i^l$ with some scaling γ along with some additional “jitter” ϵ :

$$\Theta_{i+1}^j = \Theta_i^j + \gamma \times (\Theta_i^k - \Theta_i^l + \epsilon) \quad (91)$$

In the case where the behavior of chains k and l are approximately independent of each other and assuming the underlying posterior distribution $\mathcal{P}(\Theta)$ is Gaussian with some unknown mean μ and covariance \mathbf{C} (and “standard deviation” $\mathbf{C}^{1/2}$), it is straightforward to show that the distribution of $\Theta_i^k - \Theta_i^l$ will then follow

$$\Theta_i^k - \Theta_i^l \sim \mathcal{N} [\mathbf{0}, (2\mathbf{C})^{1/2}] \quad (92)$$

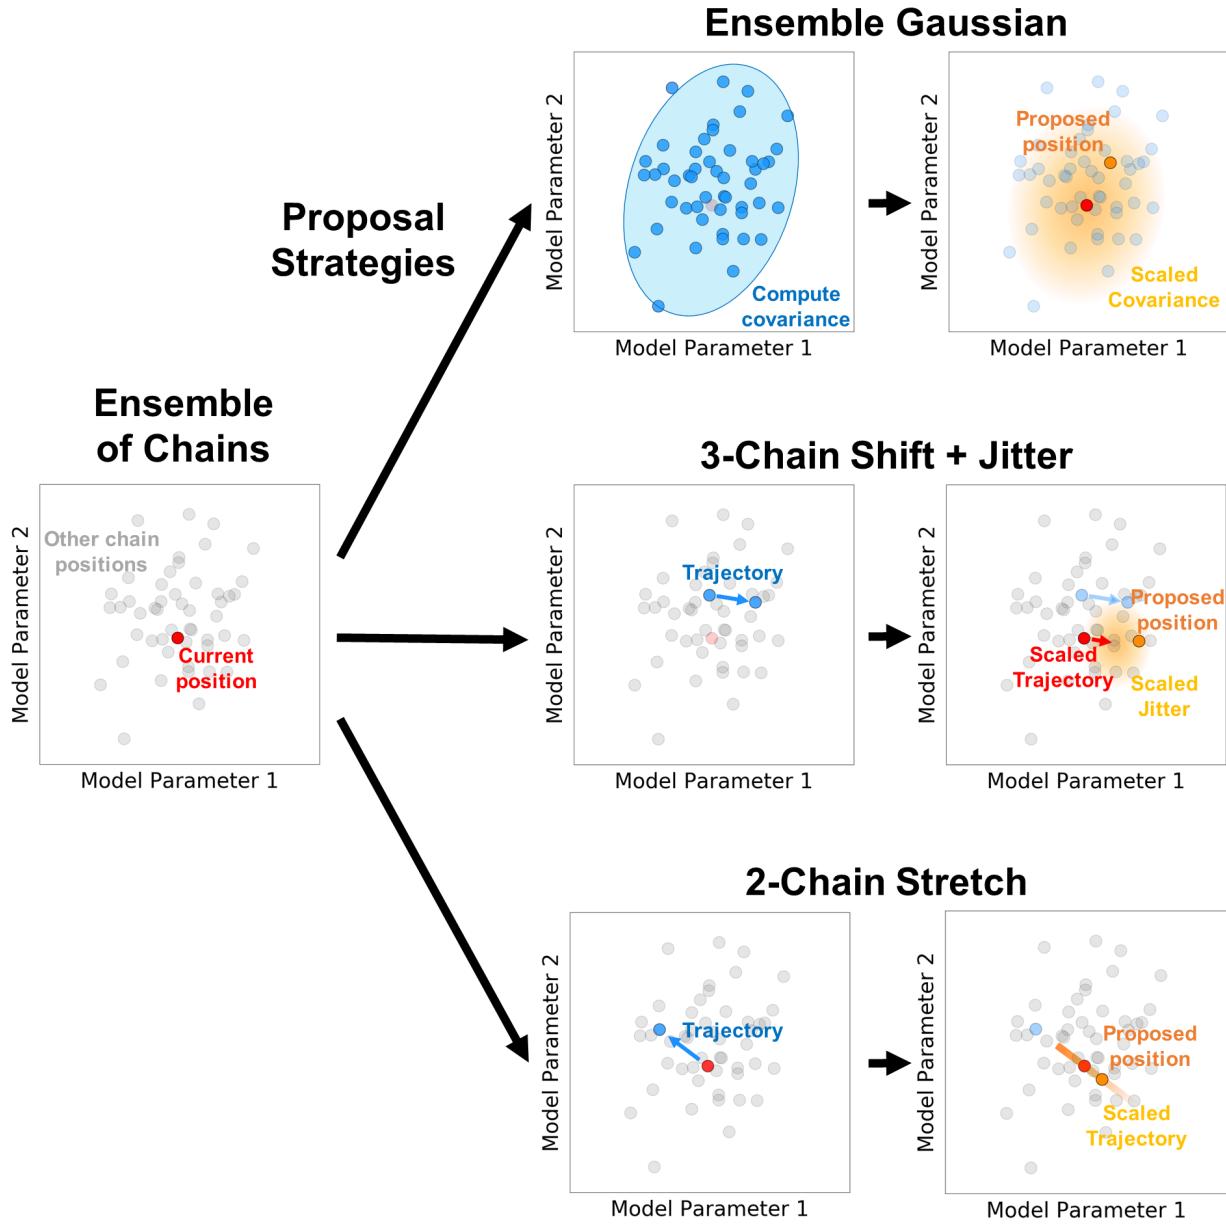


Рис. 14: A schematic illustration of the three ensemble MCMC methods described in §8.3. The current state of the chain we are interested in updating (red) and the other chains in the ensemble (gray) are shown on the left. In the top panels (ensemble Gaussian; §8.3.1), we compute the covariance of the other $k \neq j$ chains (middle) and use a scaled version to subsequently propose a new position. In the middle panels (3-chain shift + jitter; §8.3.2), we use two additional chains $k \neq l \neq j$ to compute a trajectory. We then propose a new position based on this scaled trajectory plus a small amount of “jitter”. In the bottom panels (2-chain stretch; §8.3.3), we use only one additional chain $k \neq j$ to propose a new trajectory. We then propose a random position along a scaled version of this trajectory with the proposal probability varying as a function of scale. See §8.3 for additional details.

Typically, the jitter ϵ is chosen to also be Gaussian distributed with covariance \mathbf{C}_ϵ such that

$$\epsilon \sim \mathcal{N} [\mathbf{0}, \mathbf{C}_\epsilon^{1/2}] \quad (93)$$

In general, \mathbf{C}_ϵ is mostly used to try and avoid issues caused by finite particle sampling: since the number of unique trajectories (ignoring symmetry) is

$$n_{\text{traj}} = \binom{m-1}{2} = \frac{(m-1)!}{2!(m-3)!} = \frac{(m-1)(m-2)}{2}$$

if m is sufficiently small the DE-MCMC procedure can only explore a small number of possible trajectories at any given time, leading to extremely inefficient sampling.

Combined, this implies that the proposed position has a distribution of

$$\Theta_{i+1}^j \sim \mathcal{N} [\Theta_i^j, \gamma \times (2\mathbf{C} + \mathbf{C}_\epsilon)^{1/2}] \quad (94)$$

This shows that the 3-particle DE-MCMC procedure can generate new positions in a manner analogous to the ensemble Gaussian proposal we first discussed.

8.3.3 Affine-Invariant Transformations of Ensemble Trajectories

Another approach used in the literature (e.g., emcee; Foreman-Mackey et al., 2013) is the Affine-Invariant “stretch move” from Goodman & Weare (2010). This uses only one additional particle Θ_i^k rather than two:

$$\Theta_{i+1}^j = \Theta_i^k + \gamma \times (\Theta_i^j - \Theta_i^k) \quad (95)$$

In place of the jitter term ϵ from DEMCMC, the stretch move instead injects some amount of randomness by allowing γ to vary. By sampling γ from some probability distribution $g(\gamma)$, we allow the proposals to explore various “stretches” of the direction vector. As shown in Goodman & Weare (2010), if this function is chosen such that

$$g(\gamma^{-1}) = \gamma \times g(\gamma) \quad (96)$$

then this proposal is symmetric. Typically, $g(\gamma)$ is chosen to be

$$g(\gamma|a) = \begin{cases} \gamma^{-1/2} & a^{-1} \leq \gamma \leq a \\ 0 & \text{otherwise} \end{cases} \quad (97)$$

where $a = 2$ is often taken as a typical value. Note that when $\gamma = 1$, this move leaves $\Theta_{i+1}^j = \Theta_i^j$ unchanged.

Compared to DEMCMC, the stretch move appears to have one clear advantage: it doesn’t have any reliance on some “jitter” term ϵ that reintroduces scale-dependence into the proposal. That makes the proposal invariant to affine transformations and only sensitive to a single parameter a , which governs the range of scales the stretch factor γ is allowed to explore.

This lack of jitter, however, is not substantially advantageous in practice. As noted in §8.3.2, ϵ is really designed to avoid possible degeneracies due to the limited number of

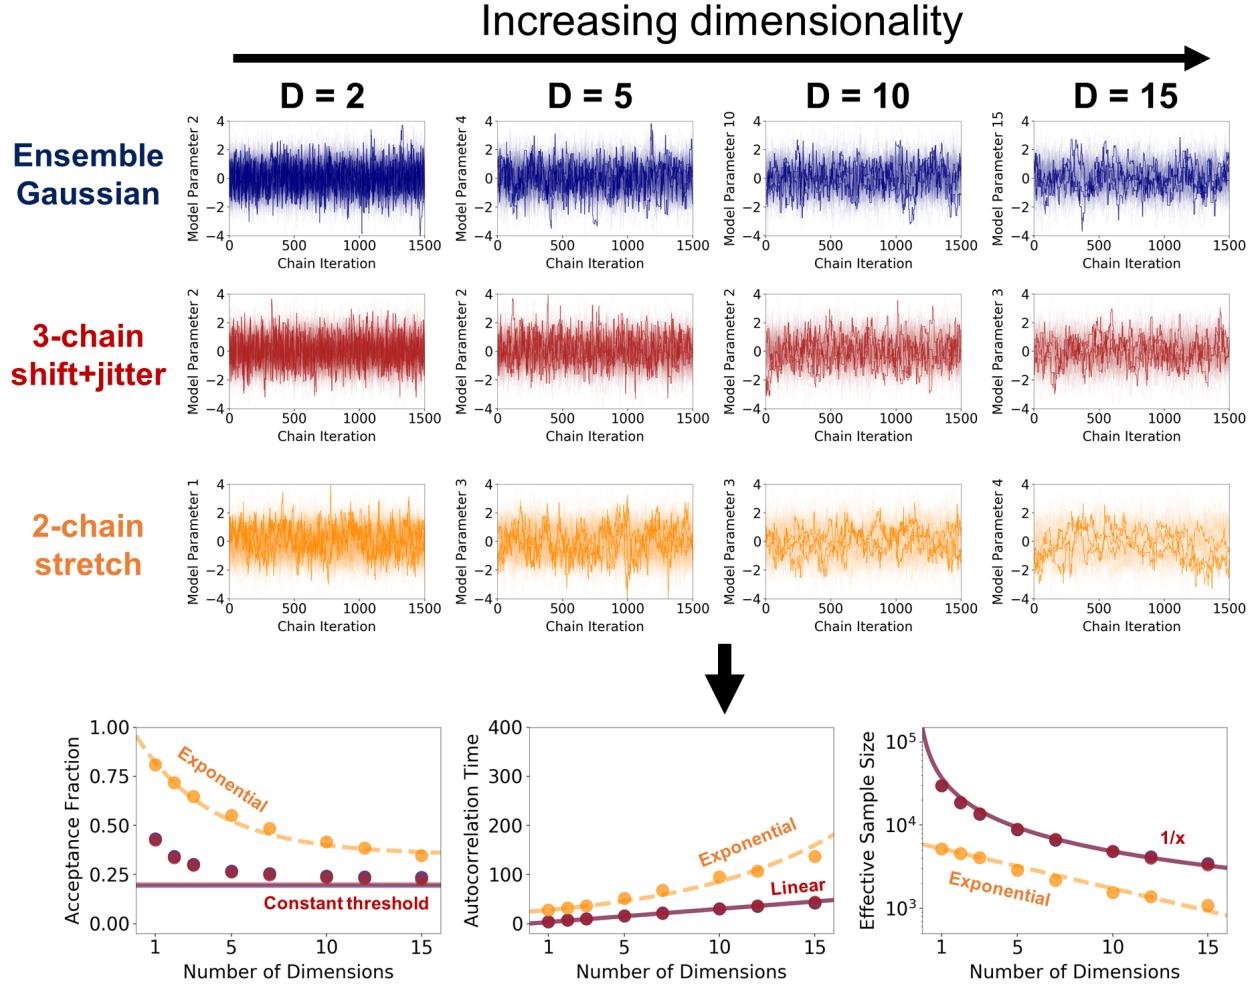


Рис. 15: Numerical results showcasing the performance of several ensemble MH MCMC samplers on our toy problem, a d -dimensional Gaussian with mean $\mu = 0$ and standard deviation $\sigma = 1$ in every dimension. The top series of panels show snapshots of a random parameter from the collection of chains (with a few chains highlighted) as a function of dimensionality (increasing from left to right) assuming ensemble Gaussian proposals with $\gamma = 2.5/\sqrt{d}$ (blue), 3-chain “shift and jitter” proposals with $\gamma = 1.7/\sqrt{d}$ (red), and 2-chain “stretch” proposals with γ drawn from the distribution $g(\gamma|a)$ with $a = 2$ as described in §8.3.3 (orange). The bottom panels show the corresponding acceptance fractions (left), auto-correlation times (middle), and effective sample sizes (right) from our chains (colored points) as a function of dimensionality. Approximations based on the §8.2 are shown as light solid colored lines, with dashed lines showing rough fits. The first two methods, which allow the size of the proposal to shrink, are able to propose samples within the bulk of the posterior mass. The last method, which is unable to do so, instead proposes exponentially fewer good positions as the dimensionality increases. See §8.3 for additional details.

available trajectories. In that case we had $(m - 1)(m - 2)/2 \sim m^2/2$ possible trajectories; here, however, we only have m (since Θ_i^j is always included). This is a much smaller number of possible trajectories at a given m , making this particular proposal more susceptible to that particular effect.

In addition, because this proposal involves adjusting γ and therefore the length of the trajectory itself, we need to consider how changing γ affects the total volume of the sphere centered on Θ_i^j with radius $\Theta_i^k - \Theta_i^j$. As discussed in §7.2, the differential volume increases as r^{d-1} . Therefore, increasing or decreasing γ substantially adjusts the differential volume in our proposal. This involves introducing a steep boost/penalty into our transition probability, which now becomes:

$$T(\Theta_{i+1}^j | \Theta_i^j, \gamma) = \min \left[1, \gamma^{d-1} \frac{\mathcal{P}(\Theta_{i+1}^j)}{\mathcal{P}(\Theta_i^j)} \right] \quad (98)$$

This heavily favors proposals with $\gamma > 1$ (outwards) and heavily disfavors proposals with $\gamma < 1$ as d increases to account for the exponentially increasing volume at larger radii.

Finally, while this stretch move actually generates proposals in the right overall direction, it is not efficient at generating samples within the bulk of the posterior mass as the dimensionality increases. As discussed in §8.2, given the typical position of Θ_i^j , the typical length-scale of the proposed positions needs to shrink by $\propto 1/\sqrt{d}$ in order to guarantee our new sample remains within the bulk of the posterior mass. However, the form for $g(\gamma|a)$ specified above instead ensures that γ will always be between $1/a$ and a . Even if we attempt to account for this effect by letting $a(d) \rightarrow 1$ as $d \rightarrow \infty$ in order to target a constant acceptance fraction and ensure more overlap, the asymmetry of our proposal and the γ^{d-1} term in the transition probability systematically biases our proposed and accepted positions compared with the ideal distribution. This subsequently leads to larger auto-correlation times, mostly counteracting any expected gains.

Numerical Tests

To confirm these results, I sample from this d -dimensional Gaussian posterior (assuming $\sigma = 1$ for simplicity) using each of these ensemble MH MCMC algorithms with $n = 1500$ iterations with $m = 100$ chains. In the first case, I propose a new position for chain j at iteration i using a Gaussian distribution with a covariance $\gamma^2 \mathbf{C}_i^j$ computed over the remaining ensemble of $k \neq j$ chains, where the scale factor $\gamma = 2.5/\sqrt{d}$ is chosen to target a constant acceptance fraction of roughly 25%. In the second case, I propose new positions using the DE-MCMC algorithm with a scale factor of $\gamma = 1.7/\sqrt{d}$ and additional Gaussian jitter with covariance $\mathbf{C}_\epsilon = \mathbf{C}_i^j / 5$ derived from the remaining chains in the ensemble, again targeting an acceptance fraction of roughly 25%. In the third case, I propose new positions using the affine-invariant stretch move assuming the typical form for $g(\gamma|a)$ with $a = 2$.⁷

As shown in [Figure 15](#), the chains behave as expected given our theoretical predictions as a function of dimensionality. Similar to the adaptive Gaussian case, the first two approaches continue sampling efficiently even as d increases. The affine-invariant stretch move, however, experiences exponentially-decreasing efficiency and struggles to sample the posterior effectively.

⁷Allowing $a(d)$ to vary as a function of dimensionality to target a roughly constant acceptance fraction gives similar results.

8.4 Additional Comments

Before concluding, I wish to emphasize that the toy problem explored in this section should only be interpreted as a tool to build intuition surrounding how certain methods are expected to behave in a controlled environment. While the behavior as a function of dimensionality helps to illustrate common issues, in practice the performance of any method will depend on the specific problem, tuning parameters, the time spent on tuning, and many other possible factors. Since it is always possible to find problems for which any particular method will perform well or poorly, I encourage users to try out a variety of approaches to find the ones that work best for their problems.

9 Conclusion

Bayesian statistical methods have become increasingly prevalent in modern scientific analysis as models have become more complex. Exploring the inferences we can draw from these models often requires the use of numerical techniques, the most popular of which is known as Markov Chain Monte Carlo (MCMC).

In this article, I provide a conceptual introduction to MCMC that seeks to highlight the what, why, and how of the overall approach. I first give an overview of Bayesian inference and discuss what types of problems Bayesian inference generally is trying to solve, showing that most quantities we are interested in computing require integrating over the posterior density. I then outline approaches to computing these integrals using grid-based approaches, and illustrate how adaptively changing the resolution of the grid naturally transitions into the use of Monte Carlo methods. I illustrate how different sampling strategies affect the overall efficiency in order to motivate why we use MCMC methods. I then discuss various details related to how MCMC methods work and examine their expected overall behavior based on simple arguments derived from how volume and posterior density behave as the number of parameters increases. Finally, I highlight the impact this conceptual understanding has in practice by comparing the performance of various MCMC methods on a simple toy problem.

I hope that the material in this article, along with the exercises and applications, serve as a useful resource that helps build up intuition for how MCMC and other Monte Carlo methods work. This intuition should be helpful when making decisions over when to apply MCMC methods to your own problems over possible alternatives, developing novel proposals and sampling strategies, and characterizing what issues you might expect to encounter when doing so.

Acknowledgements

JSS is grateful to Rebecca Bleich for continuing to tolerate his (over-)enthusiasm for sampling during their time together. He would also like to thank a number of people for helping to provide much-needed feedback during earlier stages of this work, including Catherine Zucker, Dom Pesce, Greg Green, Kaisey Mandel, Joel Leja, David Hogg, Theron Carmichael, and Jane Huang. He would also like to thank Ana Bonaca, Charlie Conroy, Ben Cook, Daniel

Eisenstein, Doug Finkbeiner, Boryana Hadzhiyska, Will Handley, Locke Patton, and Ioana Zelko for helpful conversations surrounding the material.

JSS also wishes to thank Kaisey Mandel and the Institute of Astronomy at the University of Cambridge, Hans-Walter Rix and the Galaxies and Cosmology Department at the Max Planck Institute for Astronomy, and Renée Hložek, Bryan Gaensler, and the Dunlap Institute for Astronomy and Astrophysics at the University of Toronto for their kindness and hospitality while hosting him over the period where a portion of this work was being completed.

JSS acknowledges financial support from the National Science Foundation Graduate Research Fellowship Program (Grant No. 1650114) and the Harvard Data Science Initiative.

Список литературы

- Asmussen, S., & Glynn, P. W. 2011, Statistics & Probability Letters, 81, 1482 , doi: <https://doi.org/10.1016/j.spl.2011.05.004>
- Blitzstein, J., & Hwang, J. 2014, Introduction to Probability, Chapman & Hall/CRC Texts in Statistical Science (CRC Press/Taylor & Francis Group). <https://books.google.com/books?id=ZwSlMAEACAAJ>
- Brooks, S., Gelman, A., Jones, G., & Meng, X.-L. 2011, Handbook of Markov Chain Monte Carlo (CRC press)
- Foreman-Mackey, D., Hogg, D. W., Lang, D., & Goodman, J. 2013, Pub. of the Astron. Soc. of the Pac., 125, 306, doi: 10.1086/670067
- Gelman, A., Carlin, J., Stern, H., et al. 2013, Bayesian Data Analysis, Third Edition, Chapman & Hall/CRC Texts in Statistical Science (Taylor & Francis). <https://books.google.com/books?id=ZXL6AQAAQBAJ>
- Gelman, A., & Meng, X.-L. 1998, Statist. Sci., 13, 163, doi: 10.1214/ss/1028905934
- Gelman, A., & Rubin, D. B. 1992, Statistical Science, 7, 457, doi: 10.1214/ss/1177011136
- Goodman, J., & Weare, J. 2010, Communications in Applied Mathematics and Computer Science, 5, 65, doi: 10.2140/camcos.2010.5.65
- Hastings, W. 1970, Biometrika, 57, 97, doi: 10.1093/biomet/57.1.97
- Hogg, D. W., & Foreman-Mackey, D. 2018, The Astrophys. Journal Supp., 236, 11, doi: 10.3847/1538-4365/aab76e
- Kish, L. 1965, Survey sampling, Wiley classics library (J. Wiley). <https://books.google.com/books?id=xiZmAAAAIAAJ>
- Metropolis, N., Rosenbluth, A. W., Rosenbluth, M. N., Teller, A. H., & Teller, E. 1953, Journal of Chem. Phys., 21, 1087, doi: 10.1063/1.1699114
- Neal, R. M. 2012, arXiv e-prints, arXiv:1206.1901. <https://arxiv.org/abs/1206.1901>

Skilling, J. 2004, in American Institute of Physics Conference Series, Vol. 735, American Institute of Physics Conference Series, ed. R. Fischer, R. Preuss, & U. V. Toussaint, 395–405

Skilling, J. 2006, Bayesian Anal., 1, 833, doi: 10.1214/06-BA127

Storn, R., & Price, K. 1997, Journal of global optimization, 11, 341

Ter Braak, C. J. 2006, Statistics and Computing, 16, 239

Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., & Bürkner, P.-C. 2019, arXiv e-prints, arXiv:1903.08008. <https://arxiv.org/abs/1903.08008>